



Deep Knowledge Tracingを用いた 対訳作成タスクの予測

Dynamic Crowdsourcing Task Assignment Using Deep Knowledge Tracing

立命館大学
社会知能研究室
山本 涼太郎
村上 陽平

背景

- 言語資源の作成のためクラウドソーシングが用いられている
 - 対訳作成タスクと対訳評価タスクが存在
- クラウドソーシングでは作業者の能力にばらつき
 - 低資源言語では能力の高い作業者をたくさん用意しにくい
- 作業結果の多数決を取る方法
 - 対訳の品質を保証することは難しい

		評価者						
対訳評価タスク		A	B	C	D	E	多数決	
	1: dog -> 犬	○	○	○	○	×		1
	2: cat -> 猫	○	×	○	×	×		2
	3: bird -> 鳥	×	○	×	○	×		3
								○
								×
								×
								失敗
								失敗

目的と提案手法

- 作業者とタスクのミスマッチによる対訳作成の誤り
 - 対訳作成や対訳評価のやり直しが多く発生する
 - 多数決の結果の正確性を向上する
 - 作業者ごとの作業結果の正確性を向上させる必要がある
 - 作業履歴から作業者のタスクの成功可否の確率を求める
 - Deep Knowledge Tracing(DKT)を用いる
- 
- タスクの難易度を考慮したタスク割当てに使用する

課題

- 課題. タスクごとに知識タグの付与
 - 作業者は過去に同じタスクをしているとは限らないため, タスクを知識タグごとに分類する必要がある

Deep Knowledge Tracing(DKT)

- Knowledge Tracing(KT)
 - 学習者がどの程度知識を獲得しているか予測すること
 - 主に教育分野で利用される
- KTにLong Short Term Memory(LSTM)を用いる
 - ドメイン知識を手動で入力する必要がない
 - 長期的な依存性学習が行える
- 過去の作業履歴から, 将来のタスクへのパフォーマンスを予測
- 作業者の作業毎に全ての知識タグについてスコアリング
 - 0~1.0でスコアリング

作業者のタスクの成否予測

- Deep Knowledge Tracing(DKT)を使用
- 作業者ごとに「知識タグ」「作業結果の成否(0or1)」の時系列データから予測正当確率を予測する


作業者Aのn問目までの作業履歴

問題ID	知識タグ	成否
1	3	0
2	4	1
3	0	1
4	4	0

⋮

作業者Aのn+1問目での各知識タグへの予測正当確率

問題ID	予測正当確率
0	0.580700815
1	0.571043849
2	0.586631298
3	0.567974389
4	0.588099718
5	0.575584114



この確率を
割当てに
使用する

知識タグの作成

- 知識タグ
 - 英語教育であれば, 「現在進行形」や「過去完了時制」など
 - そのタスクを解くのに必要な知識の分類
 - 評価するデータに知識タグがないため, 作成する必要
1. Word2Vecを用いてタスクの単語をベクトル化
 2. そのベクトルをk-means法を用いてクラスタリング
 3. クラスタリング結果を知識タグとして使用

知識タグの作成

- インドネシア語とミナンカバウ語の対訳評価タスクのデータ
 - インドネシア語の単語数は1002個
- 1. Word2Vecを用いてタスクの単語をベクトル化
- 2. そのベクトルをk-means法を用いてクラスタリング
- 3. クラスタリング結果を知識タグ(問題ID)として使用
- クラスタの要素数がそれぞれ5以上存在するようにする
 - クラスサイズが小さすぎるとその知識タグの予測が難しくなるため
- 1002単語に11種類の知識タグを与えた

作成した知識タグ

クラス	0	1	2	3	4
要素数	57	105	124	53	102

クラス	5	6	7	8	9	10
要素数	10	108	60	263	104	16

- 1002単語に11種類(0～10)の知識タグを割り当てた
- 各知識タグは, 大まかに規則性があるように分類できた
 - 動詞, 方向や位置に関する単語, 存在や状態に関する単語, 人の関係性を表す単語など

DKTの予測精度

- インドネシア語とミナンカバウ語の対訳評価タスクのデータ
 - 1作業者あたり約5600件の作業履歴
- 作業者ごとに成否予想を行った
- 作業者ID5,12はAccuracyが0.8以上
 - ID5,12の作業履歴をもとに正解の対訳を作成
- 他の作業者は0.6～0.7程度

作業者ID	level	Accuracy	作業者ID	level	Accuracy
1	4	0.59848	11	2	0.61295
2	3	0.74938	12	5	0.88448
3	3	0.63432	13	2	0.68439
4	2	0.63743	14	5	0.72957
5	5	0.83218	15	3	0.68283
作業者ID	level	Accuracy	作業者ID	level	Accuracy
6	2	0.66748	16	1	0.65947026
7	1	0.62764	17	4	0.70776767
8	5	0.70643	18	4	0.67304695
9	1	0.53638	19	1	0.67415982
10	3	0.71511	20	3	0.66993099

作業者20人別のDKTモデルのAccuracy

タスクの難易度を考慮した動的なタスク割当て

- 正しい対訳可能な作業者にタスクを割当てる
- 作業が進むに従い, 各作業者の得意・不得意な対訳タスクを分析し, タスク割当てに用いる
 - 作業毎に, 成否予測と割当てを行う
- DKTから得た成否予測の確率とハンガリアン法を用いる
- 成果物の正確性の向上と作業時間の最小化を目指す

タスク割当て

- タスク割当てにはハンガリアン法を用いる
- コストは, DKTから得た予測正当確率を符号反転したもの

(1) コスト行列の作成

7	5	3	8
10	7	4	3
7	3	1	7
9	8	4	1

サイズが4のコスト行列を作成

赤字は各行の最小の値

(2) 行の減算

4	2	0	5
7	4	1	0
6	2	0	6
8	7	3	0

青字は各行の最小の値

(3) 列の減算と0をカバー

0	0	0	5
3	2	1	0
2	0	0	6
4	5	3	0

0を全てカバーするには3本の線が必要

線の本数3本<行列サイズ4であるため続ける

緑字は線の引かれていない要素の最小値

(4) 最小値を引く, 足す
新しい0をカバー

0	0	0	6
2	1	0	0
2	0	0	7
3	4	2	0

線の引かれていない全ての要素から最小値を引く, 線が重なる要素は最小値を足す

0をカバーするには4本の線が必要

線の本数4=行列サイズ4のため終了



(4)の行列より, 全ての組み合わせが0になるものを選ぶことができる
この場合, [(1,1),(2,3),(3,2),(4,4)]が最もコストの低い組み合わせとなる

評価

- 今回は予備実験
- 20人分, 一人当たり140件のインドネシア語とミナンカバウ語の対訳評価タスク作業履歴を使用

評価方法

- 「動的タスク割当て」と「ランダムなタスク割当て」を比較評価
 - 作業結果のみでモデルをトレーニング

評価方法

- 20人分, 一人当たり140個のインドネシア語とミナンカバウ語の対訳評価タスク作業履歴を使用
- 140個のタスクを7つの小グループに分割し, 20人に割当てる
 - 正方行列を作成し, ハンガリアン法を適用するため
- 一人当たり7個のタスクを割当て, 正答率を確認する

成否予測を用いた動的タスク割当て

- 1問目は予測に用いるデータがないのでランダムに割当てる
- 2問目からは成否予測を用いた割当て

ランダムなタスク割当て

- 割当てを全てランダムに決定する

評価結果(成否予測を用いた動的タスク割当て)

動的タスク割当て

作業者ID	1	2	3	4	5
正当確率 (%)	85.714	71.428	57.142	85.714	100
作業者ID	6	7	8	9	10
正当確率 (%)	57.142	42.857	100	28.571	57.142
作業者ID	11	12	13	14	15
正当確率 (%)	57.142	85.714	85.714	100	85.714
作業者ID	16	17	18	19	20
正当確率 (%)	71.428	42.857	57.142	71.428	85.714

- 最低は28.571%, 最高は100%, 平均71.071%

評価結果(ランダムなタスク割当て)

ランダムなタスク割当て

作業者ID	1	2	3	4	5
正当確率 (%)	57.142	71.428	28.571	71.428	71.428
作業者ID	6	7	8	9	10
正当確率 (%)	42.857	57.142	42.857	14.286	42.857
作業者ID	11	12	13	14	15
正当確率 (%)	42.857	57.142	85.714	57.142	57.142
作業者ID	16	17	18	19	20
正当確率 (%)	28.571	42.857	28.571	42.857	71.428

- 最低は14.286%, 最高は85.714%, 平均50.714%

考察

- 時間の制約により7問目までしか割り振れなかったが, 成否予測を用いた割当ての方が正答率が高くなった
 - 知識タグと成否予測が正しくできてると言いたい割当て回数が少ない
- 予測に使える履歴が少なく, ランダムな部分が多い
 - 最後のタスク割当てですら, 6個の作業履歴しか使えない
 - 正方行列を作成するための, 小グループの分割方法を工夫
- 知識タグの作成方法も他の手法を用いる
- 作業履歴をある程度学習させた場合の実験をする必要がある

まとめ

- 知識タグをクラスタリングによって生成することで, 知識タグがないタスクをDeep Knowledge Tracingを用いて成否予測することができた
- 動的なタスク割当てをすることができたが, 割当て回数が少なく適切な評価ができなかった
- 評価を進めていく中で, 知識タグの有効性を調べる
 - 知識タグの作成方法を他にも試す