

情報処理学会 第87回全国大会

翻訳エージェントのためのプロンプト記法

加奥 咲江 (立命館大学)
村上 陽平 (立命館大学)

背景

- グローバル化の進展により多文化コミュニケーションが重要
- 機械翻訳の発展
- 多義語や文化依存の言葉を文脈に合わせて訳するのが困難
 - 多義語：bank = 銀行、河岸
 - 文化依存の言葉：public school = 公立学校（米）、私立学校（英）




翻訳エージェント

- ユーザとのインタラクションを通じて翻訳を生成する機械^[1]
- プロンプトで記述
 - 自然言語の課題
 - ユーザと会話を続けるうちに、一貫性が失われる可能性がある

[1] Chungi Shi, Toru Ishida, Donghui Lin: Translation Agent: A New Metaphor for Machine Translation, New Generation Computing, Vol.32, pp.163-186 (2014).

目的

- 文脈を正確に反映できる翻訳エージェントを実現
- 特定のLLMに依存しない構造化されたプロンプト記法の提案
- 一貫性が失われないよう、**YAML**で記述



シンタックス

- 状態遷移のモデルに基づく**文法**を定義
 - シナリオ (Scenario) : 全体の流れ
 - イベント (Event) : 状態遷移の条件
 - アクション (Action) : 動作

シンタックス 具体例

● シナリオ(Scenario)

```
def_scenario:  
  name: シナリオ全体の名前を定義する  
  states: シナリオ内の状態を定義する  
    name: 状態の名前を定義する  
  rules: 状態遷移の条件を記述する  
    event: 状態遷移を引き起こすトリガーを定義する  
    actions: イベントが発生した際に実行される動作をリストにする  
      action: 実行されるアクションの名前を指定する  
    go_state: イベント発生後に移行する次の状態を指定する
```

● イベント(Event)

```
def_event:  
  name: イベントの名前を指定する  
  content: イベントの条件またはトリガーについて説明する
```

● アクション(Action)


```
def_action:  
  name: アクションの名前を指定する  
  function: アクションの機能について説明する
```

語句

- 手順や操作が持つ**意味**を定義
- **イベント**（状態遷移の条件）： **2個**
 - **received_message** ： ユーザーからメッセージを受信したときに発生する
 - **ambiguity_detected** ： 受信したメッセージで語義の曖昧さが検出されたときにトリガーになる
- **アクション**（動作）： **3個**
 - **check_ambiguity** ： Chat GPT自体が受信したメッセージが語句の曖昧であるか判断する
 - **ask_clarification** ： メッセージ内の語義の曖昧さを明確にするには、ユーザーに英語で具体的な質問をする
 - **translate_and_display** ： メッセージを日本語に翻訳し、翻訳結果を表示する

シナリオ

- シンタックス、語句を使用して操作を行う**手順**を定義
- **状態：3個** (メッセージ待機, 確認, 明確化)



イベント(条件) /
アクション(動作)

***ambiguity** : 多義語, 文化依存の言葉, 口語表現

「メッセージ確認」状態の比較

YAML

- 構造化できる

```
- name: "Waiting for Message"
  rules:
    - event: "receive_message"
      actions:
        - action: "check_ambiguity"
      go_state: "Confirmation"
```

自然言語

- 柔軟な表現できる

ユーザーからメッセージを受信すると, ChatGPT 自体が受信メッセージに語句の曖昧があるかどうかを判断する

「確認」状態の比較

YAML

- 構造化できる

```
- name: "Confirmation"
  rules:
    - event: "ambiguity_detected"
      actions:
        - action: "ask_clarification"
      go_state: "Clarification"
    - event: "otherwise"
      actions:
        - action: "translate_and_display"
      go_state: "Waiting for Message"
```

自然言語

- 柔軟な表現できる

受信メッセージに語義の曖昧さが検出された場合は, ユーザーに英語で具体的な質問をし, メッセージ内の語義の曖昧さを明確にする.

受信メッセージに語義の曖昧さが検出されない場合は, メッセージを日本語に翻訳し, 翻訳結果を表示して, ユーザーからの次のメッセージを受信するのを待つ.

「明確化」状態の比較

YAML

- 構造化できる

```
- name: "Clarification"
  rules:
    - event: "receive_message"
      actions:
        - action: "check_ambiguity"
      go_state: "Confirmation"
```

自然言語


- 柔軟な表現できる

ユーザーからの説明を受け取った後、ChatGPT 自体が受信メッセージが語句の曖昧があるかどうかを判断する。
受信メッセージに語句の曖昧さが検出された場合は、ユーザーに英語で具体的な質問をして、メッセージ内の語義の曖昧さを明確にする。

実験


- **曖昧性検査の網羅性実験**

- プロンプトを英文を送るごとに一緒に送り、その前の返答分は受け継がないものとし、さまざまな英文に対応できるかといった網羅性を検証



- **対話継続性の評価実験**

- プロンプトを最初の1回しか送らず、英文を送り連続した対話の中でのエージェントの継続性を検証





データセット

- 多義語や文化依存単語を**含む**テスト文と**含まない**テスト文を使用

【テスト文の内訳】 総数: 200 文

- 語句の曖昧性あり：100 文
 - 多義語：60 文
She saw a match. (スポーツの試合/マッチ棒)
 - 文化依存単語：20 文
I have the casket. (棺/宝箱)
 - 口語表現：20 文
I saw the GOAT climbing to the top. (やぎ/史上最高の人)
- 語句の曖昧性なし：100 文

実験環境



曖昧性検査の網羅性実験：英文200文（曖昧性を含む英文：100文 + 曖昧性を含まない英文を100文）

対話継続性の評価実験：英文100文（曖昧性を含む英文：50文 + 曖昧性を含まない英文を50文）

● 評価項目

- 曖昧性の検査精度：曖昧性を判断し, ユーザに聞き返すことができるか
- 翻訳精度：正しい翻訳を行うことができるか
- シナリオ逸脱頻度：定義したシナリオから逸脱しないか(対話継続性の評価実験のみ)

曖昧性検査の網羅性実験 結果

● GPT 3.5 turbo

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	1372	7	10
自然言語	264	58	68

● GPT 4o mini

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	1195	53	36
自然言語	328	91	85

● GPT 4o

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	921	95	94
自然言語	352	98	96

曖昧性検査の網羅性実験 結果

● GPT 3.5 turbo

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	1372	7	10
自然言語	264	58	68

● GPT 4o mini

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	1195	53	36
自然言語	328	91	85

● GPT 4o

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	921	95	94
自然言語	352	98	96

曖昧性検査の網羅性実験 結果

● GPT 3.5 turbo

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	1372	7	10
自然言語	264	58	68

● GPT 4o mini

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	1195	53	36
自然言語	328	91	85

● GPT 4o

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	921	95	94
自然言語	352	98	96

曖昧性検査の網羅性実験 結果

● GPT 3.5 turbo

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	1372	7	10
自然言語	264	58	68

● GPT 4o mini

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	1195	53	36
自然言語	328	91	85

● GPT 4o

	平均プロンプト長 (トークン数)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	921	95	94
自然言語	352	98	96 18

対話継続性の評価実験 結果

● GPT 3.5 turbo

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	0	100	0	0
自然言語	5572	40	72	72

● GPT 4o mini

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	14106	60	88	88
自然言語	8144	40	85	85

● GPT 4o

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	8897	0	92	92
自然言語	4060	0	85	85 ₁₉

対話継続性の評価実験 結果

● GPT 3.5 turbo

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	0	100	0	0
自然言語	5572	40	72	72

● GPT 4o mini

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	14106	60	88	88
自然言語	8144	40	85	85

● GPT 4o

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	8897	0	92	92
自然言語	4060	0	85	85 ₂₀

対話継続性の評価実験 結果

● GPT 3.5 turbo

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	0	100	0	0
自然言語	5572	40	72	72

● GPT 4o mini

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	14106	60	88	88
自然言語	8144	40	85	85

● GPT 4o

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	8897	0	92	92
自然言語	4060	0	85	85 ₂₁

対話継続性の評価実験 結果

● GPT 3.5 turbo

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	0	100	0	0
自然言語	5572	40	72	72


● GPT 4o mini

	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	14106	60	88	88
自然言語	8144	40	85	85

● GPT 4o


	平均プロンプト長 (トークン数)	逸脱(%)	曖昧性検査精度 (%)	翻訳精度 (%)
YAML	8897	0	92	92
自然言語	4060	0	85	85 ₂₂

対話継続性の評価実験 結果 1 (GPT 3.5 turbo モデル)




- YAMLは曖昧性を聞き返すことができなかった
- 自然言語プロンプトの方が60%～80%程度の精度を維持
 - ➡ 自然言語の方が精度が高い
 - ➡ YAMLプロンプトが長すぎるため処理しきれなかった

対話継続性の評価実験 結果2 (GPT 4o mini モデル)



- YAMLの曖昧性検査精度は85%～95%と高め
 - YAMLは自然言語よりも安定している
 - 自然言語プロンプトは,精度が低くバラつきが大きい
- ➡ **YAMLの方が精度が高い**

対話継続性の評価実験 結果3 (GPT 4o モデル)



- YAMLの曖昧性検査精度がほぼ90%を維持し、非常に安定
 - YAMLはプロンプトが長くなっても精度が落ちにくい
 - 自然言語プロンプトは精度が低めでバラつきあり
- ➡ YAMLが精度が高く、一貫した精度を維持できる

まとめ・今後の展望

● まとめ

- 翻訳エージェントのプロンプトをYAMLで構造化し提案した
- YAMLは高性能モデルで効果的
- 自然言語は低性能モデルに有効
- LLMの性能が低いとYAMLの構造を理解できていない
- YAMLの曖昧性検査精度は、モデルが高精度になるほど優位

● 今後の展望

- さらに簡潔なYAMLプロンプトを設計し、低性能LLMでも適用可能にする
- さまざまなLLMモデルでの比較を行い、汎用的なプロンプト設計を目指す