




BERTを用いた複合サービス推薦

立命館大学情報理工学部
中川真一 村上陽平

研究背景

- インターネット上には多数のWebサービスが存在する
- それらを組み合わせたサービスを**複合サービス**という
- 新たに複合サービスを構築することを**サービス合成**という



stripe



Webサービス

複合サービス

先行研究


- 垂直型サービス合成
 - 人工知能のプランニング技術を用い、定義されたゴール状態に到達可能とするWebサービスの実行系列を生成するアプローチ
 - Carmanらは、サービス合成を計画問題と捉え、サービス合成アルゴリズムを構築した[1]
 - ユーザがゴールを論理式で設定することは**困難**
- 水平型サービス合成
 - 所与のワークフローに対して、各タスクを実行するのに適したWebサービスの最適な組み合わせを選択するアプローチ
 - Zengらは、サービス品質に着目し、同一の機能を持ったサービスの中からサービス品質を重視したサービスを選択する複合サービス合成を提案した[2]
 - 事前にワークフローを与える必要があり、その**構築コストが高い**
- 多くのwebサービスからユーザが**低コスト**で必要なサービスを選択することができるようにする必要がある

[1] Mark A. Carman, Luciano Serafini, Paolo Traverso: "Web Service Composition as Planning," ICAPS 2003 Workshop on Planning for Web Services, pp. 1636-1642 (2003).

[2] Liangzhao Zeng, Boualem Benatallah, Anne H. H. Ngu, Marlon Dumas, Jayant Kalagnanam, Henry Chang: "QoS-aware middleware for Web services composition," IEEE Transactions on Software Engineering, vol. 30, no. 5, pp. 311-327 (2004).

研究の目的と提案手法


- 研究の目的
 - ユーザの自然言語の要件定義からWebサービスを適切に発見できる
- 提案手法
 - BERTを用いてユーザの要件定義からサービスの組み合わせを推薦する手法



マルチラベル分類

- マルチラベル分類問題
 - テキストに付与されている複数のラベルを予測する問題
 - テキストが保持する複数の側面を考慮したラベルを適切に割り当てることが求められる
 - 多クラス分類とは異なり予測するラベルは複数


ドイツの水族館で飼育されていたマダコのパウル君はサッカードイツ代表の国際試合の前に「どちらの国が勝利するか」という予言を行う。



動物・スポーツ・予言


複合サービス推薦の定式化

- 複合サービス推薦をマルチラベル分類として定式化
 - 入力：サービスの説明文
 - 出力：マルチホットベクトル
 - マルチホットベクトルの各次元がカテゴリに対応




課題

- 予測したいラベル数が膨大になると予測精度を大幅に下げる
 - モデルの学習するラベルがほとんど0である
 - 関連するラベルを正確に1と予測するのが難しい
 - ラベルの不均衡




多層マルチラベル分類

- 多層でマルチラベル分類を行うことで解決




カテゴリの階層化

- 今回使用したWebサービスのカテゴリ数は152
- カテゴリ名をベクトル化し, クラスタリングを行う
 - Word2vecを使用
 - Balanced K-means法で段階的にクラスタリング
 - 大カテゴリ:152カテゴリを8等分
 - 中カテゴリ:各大カテゴリを4等分(32個)
 - 小カテゴリ:中カテゴリ内の各カテゴリを小カテゴリとする



推薦モデルの作成

- 学習データはサービスの説明文とモデルが予測したいカテゴリ
- 多段階マルチラベル分類を実現するために41個のモデルを作成
 - 大カテゴリ予測モデル：1個
 - 中カテゴリ予測モデル：8個
 - 小カテゴリ予測モデル：32個
- BERTは英語の事前学習済みモデルを使用
- 作成したモデルを組み合わせ多段階マルチラベル分類を行う



例：多段階マルチラベル分類

テキスト

Instantly Find and Embed Videos for all the products you sell, ...

STEP1

大カテゴリを予測する

(1, 0.76)

(2, 0.99)

(5, 0.59)

STEP2

中カテゴリを予測する

(1-3, 0.93)

(1-2, 0.61)

(2-0, 0.99)

(5-3, 0.99)

STEP3

小カテゴリを予測する

(social, 0.97)

(media, 0.99)

(video, 0.99)

(ecommerce, 0.96)

予測

[social, media, video, ecommerce]

正解

[social, video]

適合率 : 0.5
再現率 : 1.0
F1スコア : 0.67

データセット

- 使用したデータはprogrammablewebから取得したデータ
 - 学習データは19746件 検証データは2434件
- データ構造

```
"beanvest": [
```

```
[
```

```
"stocks",
```

```
"financial",
```

```
"stocks"
```

```
],
```

```
" Beanvest is an investment portfolio ...",
```

```
4
```

```
],
```

サービス名

構成カテゴリ


サービス説明文

id

評価方法:多段階マルチラベル分類


- 比較手法：一段階マルチラベル分類
 - サービス説明文から直接中カテゴリor小カテゴリを予測する手法
- 評価手法
 - 適合率
 - $Precision = \frac{\text{正解したカテゴリ数}}{\text{予測したカテゴリ数}}$
 - 再現率
 - $Recall = \frac{\text{正解したカテゴリ数}}{\text{テストデータで正解のカテゴリ数}}$
 - F1スコア
 - $F1score = \frac{2 \times Precision \times Recall}{Precision + Recall}$

多段階推薦と一段階推薦の中カテゴリ推薦精度比較




- 中カテゴリ推薦を行った
- 32個の中カテゴリを推薦

多段階推薦と一段階推薦の比較



- 小カテゴリ推薦を行った
- 152個の小カテゴリ推薦
- 予測するカテゴリ数が増えるほど多段階で精度が向上する

考察:学習データ数と精度の関係



多段階マルチラベル分類の学習データ数別のF1スコアの上昇率

考察:学習データの不均衡

各カテゴリ分類モデルの学習データの不均衡比の平均

モデル	学習データの不均衡比
一段階	643
大カテゴリ	5.60
中カテゴリ平均	7.79
小カテゴリ平均	50.11

- 不均衡な学習データでの学習はモデルの精度低下の原因
- 不均衡比 = $\frac{\text{最大カテゴリのデータ数}}{\text{最小カテゴリのデータ数}}$
- 各モデルの学習データの不均衡比
- 一段階は不均衡なデータから学習したため精度が下がった
- 多段階は均衡なデータから学習が行われたので精度良く推薦した
- カテゴリの階層化でデータを均衡にしたため精度が改善した

まとめ・今後の展望

- まとめ
 - BERTを用いて自然言語で記述されたユーザの要件定義から要件を満たすカテゴリの組み合わせを選択する手法を構築した
 - 多段階でマルチラベル分類をすることで精度が改善された
- 今後の展望
 - サービス推薦の精度を向上
 - より精度の良いハイパーパラメータを検証する