

情報処理学会 第87回全国大会


Deep Knowledge Tracingを用いた 対訳評価タスクの割当て

山本 涼太郎, 村上 陽平
立命館大学大学院 情報理工学研究科

背景



- インドネシアでは700以上の言語が話されている
- 147の地方言語が消滅の危機に瀕している
- コミュニケーション支援のためバイリンガル辞書が必要



- バイリンガル辞書はクラウドソーシングを用いて作成

問題点

依頼者

タスクを作業者に
に割当て

対訳作成・
評価依頼

対訳獲得

対訳作成
作業員

対訳作成
タスクの実行


"correct"

対訳評価
作業員

対訳評価
タスクの実行

多数決

"wrong"



問題点

依頼者

タスクを作業者に
に割当て

対訳作成・
評価依頼

対訳獲得

対訳作成
作業者

対訳作成
タスクの実行


"correct"

対訳評価
作業者

対訳評価
タスクの実行

多数決

"wrong"



問題点

割当ての問題点

- タスクを成功する人にタスクを割当てないと作業が増加する可能性

低資源言語の問題点

- 高スキルの作業者の確保
- 対訳の品質の保証の難しさ

対訳評価タスク	評価者					多数決 ➡		
		A	B	C	D		タスク	成否結果
	1: dog -> 犬	○	○	○	○		1	○
	2: cat -> 猫	○	×	○	×		2	×
	3: bird -> 鳥	×	○	×	○		3	○


失敗

目的

- 多数決の結果の正確性を向上する
 - 作業者ごとの作業結果の正確性を向上させる必要がある
- 作業者のスキルとタスクのミスマッチを減らす
- タスク割当ての最適化を行う
 - 再作業によるコストを削減
 - 全体的な作業時間を短縮する

提案手法

- 過去の作業履歴から作業者のタスクの成功可否の確率を求める
 - Deep Knowledge Tracing(DKT)を用いたタスク成功率予測



- タスクの難易度を考慮したタスク割当てに使用する
 - ハンガリアン法を拡張した多対多の最適割当て手法

Deep Knowledge Tracing(DKT)

- Knowledge Tracing(KT)
 - 学習者がどの程度知識を獲得しているか予測すること
 - 主に教育分野で利用される
 - 0~1で成否を予測
- KTにLong Short Term Memory(LSTM)用いる
 - ドメイン知識を手動で入力する必要がない
 - 長期的な依存性学習が行える

Deep Knowledge Tracing(DKT)

- 入力データ
 - 作業者ID, 知識タグ, タスク結果(成功または失敗)
 - 例: 作業者1が知識タグ 2 のタスクに成功した場合 (1,2,1)が入力
- モデルの動作原理
 - 各時点 t において作業履歴をもとに次のタスク成功確率を予測
 - RNN構造を利用して, 過去の履歴を逐次的にモデルに蓄積

隠れ層の更新

$$h_t = f(W_{ih}x_t + W_{hh}h_{t-1} + b_h)$$

x_t : 時刻 t における入力

h_t : 隠れ層の状態

f : 活性化関数

出力層の計算

$$y_t = g(W_{hp}h_t + b_o)$$

y_t : 次タスクの成功確率($0 \leq y_t \leq 1$)

g : シグモイド関数

知識タグ

知識タグの役割

- 各タスクをスキルや知識に基づいて分類するラベル
- 同じ知識タグを持つタスクは類似のスキルが必要と仮定
 - 英語教育であれば、「現在進行形」や「過去完了時制」など
- DKTで予測するために必要
 - しかし, 本研究で評価するデータに知識タグがない

本研究では, 知識タグを作成する必要がある

知識タグ: 知識タグの作成

- インドネシア語とミナンカバウ語の対訳評価タスクのデータ
 - インドネシア語の単語数は986個
- 1. Word2Vecを用いてタスクの単語を300次元のベクトル化
- 2. そのベクトルをk-means法を用いてクラスタリング
- 3. クラスタリング結果を知識タグ(問題ID)として使用
- クラスタの要素数がそれぞれ5以上存在するようにする
 - クラスサイズが小さすぎるとその知識タグの予測が難しくなるため
- 986単語に10種類の知識タグを与えた

知識タグ: 作成した知識タグ

クラス	0	1	2	3	4
要素数	57	105	124	53	102
カテゴリー	時間・順序	動詞	疑問	理由・結果	方向・位置

クラス	5	6	7	8	9
要素数	10	108	60	263	104
カテゴリー	義務・必要性	存在・状態	動詞	人間関係	性格・状態


- 986単語に10種類(0～9)の知識タグを割り当てた
 - タスク約5500件に存在するソースワード986単語
- 各知識タグは, 大まかに規則性があるように分類できた

タスク割当て

ハンガリアン法

- 限られた作業者とタスク間のコストを最小化する割当て
- Input: コスト行列
- Output: 各ワーカーに1つの最適なタスクが割当てられる
- 1対1の割当て問題に対してにしか使用することができない

		Cost matrix Worker ID				
Task ID		1	2	3	4	5
	1	9	2	7	8	6
	2	6	4	3	7	8
	3	5	8	1	8	7
	4	7	6	9	4	2
	5	8	3	6	2	9



タスク割当て: 拡張ハンガリアン法

クラウドソーシングでの課題

- 多対多割当てが必要
- 作業者数 $\neq$ タスク数(不一致のことが多い)

拡張のアプローチ

- 作業者の行を複製(作業者数 $<$ タスク数)
- タスクの列を複製(タスク数 $<$ 作業者数)
- 余分な行や列を0で埋める

成功確率の反転

- 成功確率をコストとしているため,全体のコストが最大となる組み合わせが欲しい

実験: 実験の概要

目的

- 提案手法(DKTを用いた割当て手法)の効果検証
- 他の割当て手法と比較し, 精度の評価を行う

比較する手法

- DKTを用いた割当て手法(提案手法)
- 実際の正当割合を用いた割当て手法
- ランダムな割当て手法

実験: 実験に使用したデータ

データセットの概要


- 対象言語: インドネシア語 - ミナンカバウ語の単語ペア
- タスク内容: 単語ペアの翻訳評価

Data for Experiment

- 作業履歴: 一人当たり1450タスク
- 知識タグ: 10 種類
- 作業人数: 20 人
- テストデータ: 500 タスク

実験: DKTを用いた割当て手法

- 作業履歴1450件でモデルをトレーニング
- 割当てるタスク500件をDKTモデルの成否予測を使い20人の作業者に割当てる(一人当たり25タスク)
- 成否予測結果がコスト行列の要素



実験: DKTを用いた割当て手法の結果

Worker	Correct (%)	Worker	Correct (%)
1	72.0	11	68.0
2	84.0	12	96.0
3	64.0	13	80.0
4	64.0	14	88.0
5	72.0	15	84.0
6	84.0	16	72.0
7	72.0	17	72.0
8	72.0	18	72.0
9	68.0	19	72.0
10	68.0	20	84.0

平均: 75.4%

実験: 実際の正当割合を用いた手法

- 作業履歴1450件を使い, 各作業者が各知識タグに対しての正当割合計算する
- 割当てるタスク500件を正当割合を使い20人の作業者に割当てる(一人当たり25タスク)
- 正当割合がコスト行列の要素

Work history

Knowledge Tag	worker	result
1	1	1
1	1	1
1	1	0
2	1	1
2	1	0
2	1	0



Fair percentage of work history for Worker 1

Knowledge Tag	Fair proportion
1	0.6667
2	0.3333

実験: 実際の正当割合を用いた手法の結果

Worker	Correct (%)	Worker	Correct (%)
1	60.0	11	72.0
2	80.0	12	88.0
3	56.0	13	84.0
4	72.0	14	68.0
5	92.0	15	84.0
6	76.0	16	72.0
7	76.0	17	64.0
8	60.0	18	56.0
9	56.0	19	80.0
10	84.0	20	80.0

平均: 73.0

実験: ランダムな割当て手法

- 割当ててるタスク500件をランダムに5回割当ててる
- 作業者ごとに5回の正答率の平均をとる(一人当たり25タスク)
- ランダムであるため, 拡張ハンガリアン法は使用しない

実験: ランダムな割当て手法の結果

Worker	Correct (%)	Worker	Correct (%)
1	64.0	11	64.8
2	72.0	12	91.2
3	68.0	13	76.0
4	61.6	14	70.4
5	88.8	15	81.6
6	52.0	16	79.2
7	54.4	17	64.8
8	81.6	18	68.0
9	64.8	19	59.2
10	64.8	20	68.8

平均: 69.8%

結果

DKTを用いた手法は,
実際の正当割合を用いた手法に比べて
2.4%
ランダムな割当て手法に比べて **5.6%** 向上した

・ 作業者1、2、6、9、14、17、18、20
提案手法がもっとも高い精度である

・ 作業者16
提案手法がもっとも低い精度である

	正答率の最高	正答率の最低	平均
1.DKT	96.0%	64%	75.4%
2.実際の正当割合	92%	56%	73.0%
3.ランダム			69.8%

考察

- 提案手法が, 比較手法に比べ正確性が最大5.6%向上した
 - 正答率が上がることで, 再作業が削減される
- DKTはリカレントニューラルネットワークである
 - 過去の履歴から継続して学習が可能
 - 柔軟に現在のスキルの変動に適応することができた
 - 作業履歴が少ない場合の割り当てはランダムに近くなる

考察: 作業者の作業の信頼度レベル

- 信頼度レベル
- データ作成者が作成した, 作業者の作業結果の信頼度を示す数値である
- 数値が高いほど, 信頼度が高い
- 本研究の正解データは, 信頼度レベル5の結果をもとに作成

worker	level	worker	level
1	4	11	2
2	3	12	5
3	3	13	2
4	2	14	5
5	5	15	3
6	2	16	1
7	1	17	4
8	5	18	4
9	1	19	1
10	3	20	3

考察: 作業者の信頼度レベル別正当割合

- 作業者の信頼度レベルが高いほど, DKTを用いた手法を使った際の正当割合が高いことがわかった.

		手法		
信頼度レベル		DKT	実際の正当割合	ランダム
	1	71%	71%	64.4%
	2	74%	76%	63.6%
	3	76.8%	76.8%	71%
	4	72%	60%	65.6%
	5	82%	77%	83%

考察: 課題

実験で使ったデータ数の問題

- 時間の制約により全てのデータを使うことができなかった
- データ量を増やすことでDKTの予測精度を上げられる

知識タグの分類方法

- Word2vecを用いた単語の意味を基準に分類した
- クラスタサイズの不均衡がDKTの予測精度に影響した可能性がある
- クラスタサイズの小さい知識タグでは, 成否予測が難しい

まとめ

研究成果

- 提案手法がクラウドソーシングにおけるタスク割当ての精度向上に寄与
- 高信頼度作業者への適用で効果を発揮
- 精度向上により, 低資源言語のバイリンガル辞書作成の効率化の可能性

今後の展望

- 実験に使用するデータの拡張, 他機械学習との比較
- 実際のクラウドソーシング現場での適用とフィードバック