

多層マルチラベル分類による 複合サービス推薦の層構成分析

立命館大学大学院 情報理工学研究科

中川真一 村上陽平

研究背景

- Webサービス：Google Mapなどインターネット上で利用できるサービス
インターネット上に多数存在する
- **複合サービス**：Webサービスを組み合わせて構築されるサービス
- **サービス合成**：新たに複合サービスを構築すること

➡ 適切なサービスの選定がサービス合成の課題である

Webサービス



地図機能



stripe

決済機能



twilio

メッセージ機能




複合サービス



民泊予約サービス

研究の目的と提案手法


- 研究の目的
 - ユーザの自然言語の要件定義文からWebサービスを適切に発見できる
- 提案手法
 - BERTを用いてユーザの要件定義からサービスの組み合わせを推薦する手法



マルチラベル分類

- マルチラベル分類問題
 - テキストに付与されている複数のラベルを予測する問題
 - テキストが保持する複数の側面を考慮したラベルを適切に割り当てることが求められる
 - 多クラス分類とは異なり予測するラベルは複数


ドイツの水族館で飼育されていたマダコのパウル君はサッカードイツ代表の国際試合の前に「どちらの国が勝利するか」という予言を行う。



動物・スポーツ・予言


複合サービス推薦の定式化

- 複合サービス推薦をマルチラベル分類として定式化
 - 入力：複合サービスの要件定義文 s
 - BERT により文章をベクトル化 $x = g_{BERT}(s)$
 - マルチラベル分類
 - ラベル集合 $Y = \{y_1, \dots, y_q\}$
 - 出力：構成サービス集合 $\hat{Y} = \{y \in Y | f(x, y) > t\}$




課題：マルチラベル分類

- 予測したいラベル数が膨大になると、推薦精度が大幅に下がる
 - 膨大な数のWebサービスを直接予測するとラベルが多すぎる
 - Webサービス出現数に偏りがある不均衡な学習データ



提案手法：多層マルチラベル分類

- **多層**でマルチラベル分類を行うことで推薦精度の低下を解決
- 多層構造のメリット：1モデルが予測するラベル数が減る



例：多層マルチラベル分類

テキスト

Instantly Find and Embed Videos for all the products you sell, ...

Layer1

1層目クラスタを予測する

(1, 0.76)

(2, 0.99)

(5, 0.59)

Layer2

2層目クラスタを予測する

(1-3, 0.93)

(1-2, 0.61)

(2-0, 0.99)

(5-3, 0.99)

Layer3

カテゴリを予測する

(social, 0.97)

(media, 0.99)

(video, 0.99)

(ecommerce, 0.96)

Layer4

Webサービスを推薦する

(facebook, 0.97)

(bbc, 0.99)

(youtube, 0.99)

(google-checkout, 0.96)

予測

[facebook, bbc, youtube, google-checkout]


正解

[youtube, facebook, vimeo, dailymotion]

適合率 : 0.5
再現率 : 0.5
F1スコア : 0.5

機能分解の段数と機能候補数

- 機能分解の段数 L : 推薦までに使用するモデルの数
- 機能候補数 N_l : 1つのモデルが分類する数



機能分解の段数と機能候補数のトレードオフ


- 段数を増やすことで
 - 各層の候補数が減少
 - 分類問題は容易になる
- 過度な多段化
 - 絞り込みを細分化しすぎることによって探索空間の削減を遅らせる
 - 上位層で誤分類すると正しい経路が削除される
 - 上位層の誤りほど最終結果への影響が大きい
- 設計指標 E を定義
 - 上位層の誤りの影響を考慮した誤分類リスクを指標化した
 - $$E = \sum_{l=1}^L w_l \frac{N_l}{N_L}, \quad w_l = \frac{L-l+1}{L}$$

結果

- 機能分解段数ごとの最良構成の推薦精度を比較
- 多層化により推薦精度が向上し、4段階構成が最良

段数	機能候補数	Precision	Recall	F1
1段階	909	0.020	0.655	0.038
3段階	(12,152,909)	0.451	0.790	0.490
4段階	(12,48,152,909)	0.513	0.765	0.538
5段階	(12,24,48,152,909)	0.444	0.670	0.455

- 設計指標 E と推薦性能の関係
- 中程度の E を持つ4段階構成が最も高いF1を達成



まとめ

- 多層マルチラベル分類による複合サービス推薦手法を提案
- 機能分解の段数と機能候補数のトレードオフを分析
- 設計指標 E を用いて階層構造を評価した
- 4段階構成が最も高いF1 (0.538) を達成