

LLMマルチエージェント型質問応答のための 弁証法的議論

立命館大学
増尾 柚希

研究背景




- 大規模言語モデルを用いた質問応答システム

- ChatGPT や Gemini
- 情報検索や翻訳

- 価値観の衝突を生む質問



- MAD（マルチエージェントディベート）を用いた回答生成

Q. どのカメラを買うべきか



携帯性に優れたカメラaを買うべきだ

性能が良いカメラbを買うべきだ




性能が良いと長期的な満足度が高くなるので、カメラbを買うべき

- 双方の価値観を包含していないため、解決していない
- 合意形成を達成する議論手法→ **弁証法議論**

アプローチ・課題

- 弁証法議論の既存手法



- 特徴：論理式を用いた形式的手法


- エージェントのスタンスや論理（知識ベース）は手動で定義する必要がある
- 議論の幅が狭く、回答が知識ベースの範疇



目的：弁証法の推論プロセスを大規模な知識ベースを学習した
LLMマルチエージェントシステムに適用する

アプローチ（プロトコル）

- プロトコルとプロンプト
 - 弁証法議論のプロトコル
 - 2体のエージェントが主張 → 反論（ループ） → 統合のステップで推論




プロセスの流れ

アプローチ（プロンプト）

- LLM出力の制御

- 出力構造や反論ルールを定義しない議論 → 表層的な反論の応酬



- 課題 → 解決策

- 論理的な発話
- 「反論できない」を判断させる



**既存手法を参考にした
出力形式の定義**

弁証法プロトコル - 主張 -

- エージェントが最初に述べる主張
 - 既存の形式的手法の論証構造 をスキーマとしてプロンプトに導入

```
Argument: {  
  "rules": [  
    {  
      "strong": ['a'はカメラ, 'a'は軽い, 'a'はコンパクト, コンパクトで軽いカメラなら買う],  
      "weak_negation": [],  
      "consequent": "カメラ aを買うべきだ"  
    },  
  ],  
  "Conclusion": ["カメラaを買う"],  
  "Assumption": []  
}
```

- strong(前提事実)
- weak_negation(仮定)
- consequent(帰結)



AG1

出力（主張）の例

弁証法プロトコル-反論-

- 相手エージェントの主張・反論に対して否定を行う
 - 既存研究に従って、以下の攻撃手法を用いて反論を行う
 - **Rebut**: 相手の結論 (Conclusion) の1つを否定
 - **Undercut**: 相手の仮定 (Assumption) の1つを否定

- can_defeat(反論可能判断)
- attack(攻撃手法)



AG1

“カメラaを買うべきだ”



```
Argument: {  
  "can_defeat": "YES",  
  "attack": "rebut",  
  "rules": [  
    {  
      "strong": ['a'は在庫切れ, 在庫切れのカメラは買わ  
ない,  
      "weak_negation": [],  
      "consequent": "aを買うべきではない"  
    },  
    ...  
  ]  
  "Conclusion": [ "aを買うべきではない",  
  "Assumption": []  
}
```



AG2

弁証法プロトコル-反論終了条件-

- 反論フェーズが終了する条件：**主張・反論が defeat された時**
 - 主張がundercutされた時
 - rebutに対してundercutができない時

```
Argument: {  
  "can_defeat": "YES",  
  "attack": "rebut",  
  "rules": [  
    {  
      "strong": ['a'は在庫切れ, 在庫切れのカメラは買わ  
ない,  
      "weak_negation": [],  
      "consequent": "aを買うべきではない"  
    },  
    ...  
  ]  
  "Conclusion": ["aを買うべきではない"],  
  "Assumption": []  
}
```

⇒ Assumptionは空、undercutは不可能



システムで主張はdefeatedと判定

弁証法プロトコル-統合-

- 最終回答（止揚論証）を生成
 - 既存研究に則り、defeatされた主張のペアに対して以下を適用
 - ① 汎化: お互いの主張の判断基準を抽出
 - ② 統合: 2つの性質が同時に成り立つ合意核を定義
 - ③ 最終回答: 合意核を満たす新たな回答を定義



AG1

コンパクトで軽いカメラaを買う



AG2

高画質でバッテリー持ちの良いカメラbを買う

コンパクトさや軽さなどの**持ち運びやすさ**と
高画質やバッテリー持ちなどの**良い性能**を持つ
カメラ

①

コンパクトで軽いカメラなら買う

②

高画質でバッテリー持ちの良いカメラなら買う

③

ユーザーフレンドリーでバッテリー持ちの良い
カメラcを選ぶ

評価手法

- 評価方針
 - 提案手法の正当性
→ 参照先の対話例との構造的な一致を確認
- 評価データ（実験）
 - 既存研究と同様の条件で行った対話ログ

AG1のスタンス：

a is a camera, c is a camera, a is compact, a is light, c has **long battery** life, c is **user-friendly**, b is over budget

If a **camera** is **compact** and **light**, we **should buy** it.

If something is over budget, we should not buy it.

If something is **compact** and **light**, it is **user-friendly**.

トピック: What camera should we buy?

AG2のスタンス：

b is a camera, a is out of stock, b has long battery life, b has high image quality

If a **camera** has high image quality and **long battery** life, we **should buy** it.

If something is out of stock, we should not buy it.



Choose **camera c**, which is a camera with **long battery** life and **user-friendly** operation, satisfying the desirable properties in the consensus core

議論構造および最終回答の一致により正当性を確認

追加実験・考察

● 応用可能性

- 合意核を満たす性質を，LLMが実在製品（例：Sony RX100 VII）に対応付けて提案するケースが確認された
 - 入力スタンスに限定されず，LLMの一般知識を活用した具体的解の生成が可能であることを確認

AG1のスタンス：

You are discussing which camera to buy.
You prioritize ease of use for the user, such as compactness and lightness.

AG2のスタンス：

You are discussing which camera to buy.
You prioritize camera performance, such as good image quality and battery life.



持ち運びやすさと性能を兼ね備えたSony RX100 VIIを提案します。

口コミ（Amazon）：一眼を使用していましたが、歳のせいか重いものを持つのが億劫になり、**コンパクトカメラ**にしました。少し明るめに写る気がしますが、旅行先でスナップ写真やちょっとした景色を取るには**十分すぎる性能**です。（星5）

まとめ

- 弁証法議論におけるプロンプトの制御
 - 出力形式（スキーマ）の提案
 - 論理的な発話を促進
 - 反論の中で攻撃対象を明確化 → 議論の深まりを促進
 - 議論の収束条件の提示
 - 主張・rebutに対するundercutによる終了
 - 最終回答（止揚論証）の生成
 - 汎化：主張の判断基準の抽出（何をもってそれをしたのか）
 - 統合：判断基準が同時に成り立つ合意核を作成（共に納得する条件）
 - 最終回答：合意核を満たす回答を生成
- 展望
 - 多様なトピックへの適用検証，異なる LLM 間での議論特性の比較，およびエージェント発言の一貫性評価手法の確立