

卒業論文

大規模言語モデルに基づく オントロジー自動構築の日本語による検証

指導教官 村上 陽平 教授

立命館大学 情報理工学部
先端社会デザインコース 4 回生
26002100303

石田 大智

2024 年度（秋学期）卒業研究 3（CH）
令和 6 年 1 月 31 日

大規模言語モデルに基づく オントロジー自動構築の日本語による検証

石田 大智

内容梗概

情報科学におけるオントロジーは、データや知識の整理、共有、利用のために、ある特定の概念化を計算機的に明確に概念クラスの意味的規約として記述したもの(概念体系)である。特に、人工知能や知識処理などの分野で重要な役割を果たす。また、特定の分野における事実、定義、ルールなどの集合体である「知識ベース」の基盤を作るためにも利用される。オントロジーを通じて、異なるシステム間で抽象度や定義が不明瞭な知識を一貫して共有することが可能となる。このようなオントロジーは人手で作成されており、膨大な労力と時間がかかっている。さらに、オントロジーの整合性や最新性を保つのが難しくなる。そのためオントロジー作成の効率化が求められており、自動化技術が重要な課題となっている。このような問題に対して、オントロジーの自動構築が試みられており、近年、大幅に精度が向上した大規模言語モデル (LLM) を適用した手法が提案されている。しかしながら、この手法は英語のプロンプトで作成し評価されており、日本語のプロンプトでどの程度有用かがわかっていない。LLM が言語に依存したモデルであることを考慮すると、日本語によるオントロジー自動構築のために、既存手法の日本語プロンプトでの評価が重要である。

そこで、本研究では日本語のプロンプトと LLM を用いてオントロジーの自動構築を行った。具体的には、日本語の LLM のマスク言語モデルを用いてマスク箇所を予測し、単語の上位概念を抽出できるかを検証する。本検証にあたり、取り組むべき課題は以下の2点である。

日本語データへの適用

既存の研究ではオントロジーの作成プロセスを3つのタスク(A:用語のタイプ分け, B:階層構造の発見, C:非階層型関係の抽出)に分けており、英語で記述されたデータとプロンプト、英語の LLM を使用している。本研究では、最初のタスク A(用語のタイプ分け)に焦点を当て、日本語で記述されたデータとプロンプト、日本語 LLM を用いて評価を行う。

特定ドメインでの適用

既存の研究ではオントロジーの作成を一般的な知識を対象として評価している。LLM の性能が学習データに依存していることから、対象が専門的に

なるほど精度が低下する事が予想されるため、現在の手法が専門分野に対してどの程度信頼性があるのかを明らかにする必要がある。

前者の課題に関してはデータを日本語に翻訳した上で、日本語に特化したマスク言語モデルを用いて予測を行う。具体的には、英語で記述されたオリジナルのデータを機械翻訳で日本語に翻訳し、日本語データによる事前学習済み **BERT** と **GPT4o-mini** を用いて、実際に **Geonames** のデータを用いて用語のタイプ分類を試みた。生成された分類においては **Mean Average Precision (MAP)** で評価した。

後者の課題に関しては、日英の言語間の精度比較ではなく、分野間の精度比較を行うために、用語のタイプ分けタスクをより専門的なドメインで検証する。具体的には、化学の分析手法分野を対象として、提案手法で自動生成したオントロジーと、人手で作成した分析手法オントロジーを比較する。化学の分析手法分野のオントロジーを自動生成するために、材料科学技術振興財団が出している分析手法カタログや、日本分析機器工業会が提供している分析機器の手引きから具体的な分析手法の説明文を抜粋し説明文を加えて分析手法の分類をマスク言語モデルに予測させる。

本研究の貢献は以下のとおりである。

日本語データへの適用

Geonames を日本語で翻訳し、日本語の **BERT** モデルを用いて予測を行った **MAP** 関数の評価は 14%であり、英語での結果である 38.3%と比べると低い結果となった。**GPT** を用いて予測を行った結果 **MAP** 関数の評価は 7%であり、こちらも英語の 35.0%と比べると著しく低い結果であった。ここまで低くなったのはより上位の概念を予測してしまうことが原因であると考えられる。逆に、より下位の概念を予測しているものを上位の概念で当てはまるか確認したが結果は1%ほどしか増加しなかった。

特定ドメインでの適用

ドメインは化学の分析手法である。このドメインで用語タイプの分類を行った結果は、二つ上の上位概念は予測することができた。しかし、汎用的なテンプレートを用いた場合は、見当違いな予測をすることがわかった。

Verification of Automatic Ontology Construction Based on Large Language Models in Japanese

Taichi Ishida

Abstract

Ontology in information science defines the semantic conventions of concept classes for organizing, sharing, and utilizing knowledge. It is essential in fields like AI and knowledge processing and serves as the foundation for knowledge bases. Traditionally, ontology construction has been manual, requiring significant effort and time, while maintaining consistency remains challenging. To address this, automation using Large Language Models (LLMs) has been explored, with recent advancements improving accuracy. However, these methods have been developed using English prompts, and their effectiveness with Japanese prompts remains unclear. Given the language dependency of LLMs, evaluating them with Japanese prompts is crucial for automatic ontology construction in Japanese. Therefore, in this study, we conducted automatic ontology construction using Japanese prompts and LLMs. Specifically, we utilized a masked language model of a Japanese LLM to predict masked portions and verify whether it can extract hypernyms of words.

For this verification, the following two key challenges need to be addressed:

Application to Japanese Data

Existing research divides the ontology creation process into three tasks: (A) term typing, (B) taxonomy discovery, and (C) extraction of non-hierarchical relations. These studies use English-written data and prompts, as well as English-based LLMs.

Application in a Specific Domain

Existing research evaluates ontology construction based on general knowledge. Since the performance of LLMs depends on their training data, accuracy is expected to decrease as the target domain becomes more specialized. Therefore, it is necessary to assess the reliability of current methods when applied to specialized fields.

For the first challenge, we translated the data into Japanese and used a Japanese-specific masked language model for prediction. Specifically, we

translated the original English data into Japanese using machine translation and applied a pre-trained Japanese BERT and GPT-4o-mini to classify term types using Geonames data. The generated classifications were evaluated using Mean Average Precision (MAP).

For the second challenge, we focused on comparing accuracy across different domains. We verify term classification in a specialized domain. We validated the term classification task in a more specialized domain by automatically generating an ontology using the proposed method and comparing it with a manually created ontology in the field of chemical analysis techniques. To generate an ontology for chemical analysis techniques, we extracted explanatory texts on specific analytical methods from catalogs published by the Foundation for Promotion of Material Science and Technology of Japan and guides provided by the Japan Analytical Instruments Manufacturers' Association. These texts were used to classify analytical methods using a masked language model.

Application to Japanese Data

We translated Geonames into Japanese and performed predictions using a Japanese BERT model. The evaluation using the MAP function resulted in a score of 14%, which is significantly lower compared to the English result of 38.3%. Similarly, when using GPT for predictions, the MAP score was 7%, which also showed a substantial drop compared to the English score of 35.0%.

Application in a Specific Domain

The domain we focused on is chemical analysis techniques. The results of term type classification showed that when using a domain-specific template, the model was able to predict the top-level concepts two levels above. However, when using a more general template, the predictions were often inaccurate.

目次

第 1 章 はじめに	2
第 2 章 関連研究	4
2.1 オントロジー	4
2.2 オントロジー自動構築.....	5
第 3 章 大規模言語モデルに基づくオントロジー自動構築	7
3.1 LLM4OL	7
3.2 マスク言語モデル.....	9
3.3 文脈を考慮した分類	10
第 4 章 実験	13
4.1 一般知識ドメイン	13
4.1.1 テンプレート	13
4.1.2 正解ラベル.....	14
4.2 専門知識ドメイン.....	15
4.2.1 化学分野における分析手法	15
4.2.2 テンプレート	16
4.2.3 正解ラベル.....	17
第 5 章 評価	18
5.1 評価手法.....	18
5.2 Geonames の分類	19
5.3 化学分析手法の分類	20
第 6 章 考察	22
第 7 章 おわりに	24
謝辞	25
参考文献	26
A.1 付録 1	26

第1章 はじめに

オントロジーは、特定の知識領域における概念やその相互関係を明確に定義し、体系的に構造化するための枠組みであり、今日の情報社会においてますます重要な役割を担っている。特に、人工知能（AI）やセマンティックウェブ、データ統合などの分野において、オントロジーは知識の共有や推論を効率的に行うための基盤となり、さまざまな知識ベースの発展に寄与している。具体的には、オントロジーを用いることで、異なるシステムやデータソース間で意味的に一貫した情報の交換が可能となり、検索エンジンや自動推論エンジンの精度向上、さらには業務プロセスの自動化においても重要な役割を果たす。しかし、オントロジー構築の現状にはいくつかの課題も存在している。まず、従来のオントロジー構築方法は、専門家による手動での作業が主流であり、そのために多大な時間と労力がかかる。このプロセスは、特に大規模な知識体系を構築する場合や、異なる分野の知識を統合する場合に困難を伴う。さらに、オントロジー構築には、高度な専門知識が求められ、特に日本語などの言語に特有の課題が存在する。例えば、日本語には同義語や語彙の曖昧性、文脈依存性といった問題があり、これらがオントロジーの自動生成を難しくしている。加えて、オントロジーの利用においては、その正確性や更新の柔軟性が求められる。従来のオントロジーは一度構築されると固定的になりがちで、環境の変化や新しい情報を反映させることが難しいという問題もある。

これらの課題に対応するためのアプローチとして、オントロジーの自動構築が近年注目されている。自然言語処理（NLP）技術を活用したテキストマイニングや機械学習、深層学習を用いたオントロジー自動生成手法の開発が進んでおり、これにより従来の手動によるオントロジー構築の負担を軽減し、大規模かつ動的な知識の構築が可能となると期待されている。しかし、こうした技術を日本語のような言語に適用するには、言語固有の問題を考慮する必要がある。本研究は、英語で行われているオントロジー研究を、日本語においても実現することを目的としている。特に、オントロジーの自動構築に焦点を当て、日本語のテキストや知識リソースを用いて、オントロジーの生成と運用を行う手法を提案している。日本語には英語と異なる文法的特徴や語彙、表現が多いため、既存のオントロジー構築手法をそのまま適用することが難しく、これに対する新たなアプローチが求められる。例えば、同義語や多義語の問題、語順の違い、助詞の使い方の違いな

ど, オントロジー構築における日本語特有の課題に対して, どのように情報を抽出し, 正確に関係性を定義するかが重要となる. また, オントロジーの構築は単なる語彙のリスト作成にとどまらず, 概念間の関係や階層構造を明確にすることが求められる.

本手法の実現にあたり, 取り組むべき課題は以下の 2 点である.

日本語データへの適応

既存の研究ではオントロジーの作成プロセスを 3 つのタスク (A:用語のタイプ分け, B:階層構造の発見, C:非階層型関係の抽出) に分けており, 英語で記述されたデータとプロンプト, 英語 LLM を使用している. 本研究では, 最初のタスク A (用語のタイプ分け) に焦点を当て, 日本語で記述されたデータとプロンプト, 日本語 LLM を用いて評価を行う.

対象となるドメインでの応用

既存の研究ではオントロジーの作成を一般的な知識を対象として評価している. LLM の性能が学習データに依存していることから, 対象が専門的になるほど精度が低下する事が予想されるため, 現在の手法が専門分野に対してどの程度信頼性があるのかを明らかにする必要がある.

以下本論文では第 2 章にオントロジーとは何かとオントロジーの自動構築に関する先行研究と本研究の基となる先行研究について説明している. 第 3 章では英語で実施されていた用語のタイプ分けの説明をしている. 第 4 章では実装された用語のタイプ分けを別のドメインで検証したことについての説明をしている. 第 5 章では用語のタイプ分けをした結果の英語モデルとの比較, 別のドメインでの検証結果について説明している. 第 6 章では第 5 章の結果を踏まえて考察を記述し, 第 7 章では本研究のまとめを述べた.

第2章 関連研究

本章では研究の本題であるオントロジーの説明と本研究で扱う「オントロジーの自動構築」についての関連研究について述べる。

2.1 オントロジー

オントロジーの自動構築をする上でまずオントロジーの説明をする。

ここでいうオントロジーとは、特定のドメイン(分野)に関する知識を構造化し、共有・再利用できる形式で表現するための枠組みのことである。オントロジーは、概念(クラス)、その属性(プロパティ)、および概念間の関係を定義することで、情報を意味的に豊かにし、コンピュータが理解しやすくする。これにより、システム間での情報共有や推論(インファレンス)が可能になる。オントロジーはいくつかの要素で構成されている。1 つ目はクラス(概念)である。これはオントロジーで定義される基本的なカテゴリや種類のことであり、クラスは、特定のドメインで重要な概念を表現する。例えば、「動物」「車」「会社」などがクラスである。2 つ目はインスタンス(個体)である。これらはクラスに属する具体的な実例を表している。例えば、「犬」や「トヨタ・カローラ」といった、具体的なオブジェクトがインスタンスに該当する。3 つ目はプロパティ(属性)である。これはクラスやインスタンスに関連する特性を表す要素である。これらは、クラスや個体が持つ属性を定義している。例えば、「色」「重さ」「大きさ」などがプロパティに当たる。4 つ目は関係である。これは異なるクラス間やインスタンス間で成立する関連性を表している。例えば、「親子関係」や「所有関係」、「場所」などの関係がこれに当たる。関係は、概念同士がどう関連しているかを示している。

オントロジーの目的は、異なるシステムやユーザー間で共通の理解を促進するために意味を共有・統一し、情報を標準的な形式で表現してデータ交換や相互運用性を確保するとともに、推論を通じて新たな知識を自動的に導き出すことにある。

オントロジーの設計には、まず対象となるドメイン(例:医療、ビジネス、交通)の選定から始まり、次にそのドメインに関連する重要な概念を定義し、概念間の関係(例:「車」と「エンジン」の「搭載する」関係)を明確化する。その後、具体的なインスタンス(例:「トヨタ・カローラ」)を定義し、最後にオントロジーに基




図 1 オントロジーのグラフ例

づく推論機能(例:「A は B より大きい」ならば「B は A より小さい」)を設計することで, 実際に運用可能な知識ベースが構築される.

2.2 オントロジー自動構築

玉川ら[1]は日本語版 Wikipedia からプロパティを備えたオントロジーを半自動的に構築することを目指した手法が提案されている. この研究では, Wikipedia の情報資源 (カテゴリツリー, Infobox, リダイレクトリンク, 一覧記事など) から, 概念および概念間の関係 (Is-a 関係, クラス-インスタンス関係, プロパティ定義域, 同義語など) を抽出し, オントロジーの構築を目指している. これまでの手法に加えて, プロパティ名を抽出するために Wikipedia 記事のリスト構造のスクレイピングを行った. 結果として 10,769 のプロパティ名を抽出, 4,867,882 のインスタンス-プロパティ-プロパティの値の組を抽出, 94%の精度であった.

藤生ら[2]は, 生産現場での過去の不良に対する分析として利用される保全記録の課題からそれらを構造化する手法が提案されている. この研究ではナレッジグラフを利用して, 行われており, 特定のキュー表現を用いて因果関係を抽出するルールベースの手法とルールベースが明示的でない因果関係に対応するため

に機械学習の手法が使われている。結果は保全記録からのイベントノードと、その属性の取得、ノードのマッチングの二つのステップにより抽出した不良箇所と手動で作成した正解データとの一致度は **0.88** で、抽出された不良状態と正解データの **BERTScore** は **0.89** であった。閾値が **1.0** のとき、ノードの数は **214** で完全にユニークなノード数となり、閾値が **0.95** のときノード数は **133** で約 **38%** のノードがマージされた。成果として、提案手法によりコストを抑えつつ保全記録の特性を反映した因果関係を表現するナレッジグラフを構築することに成功した。

Hamed ら[3]は、オントロジー学習において大規模言語モデルを活用する「LLMs4OL」を提案している。LLMs が持つ言語パターンを捉える能力を活用して自然言語テキストからの知識の自動抽出・構造化を効果的に遂行できるかどうかを9種類の LLM モデルファミリーを使用して評価した。結果として高度な推論スキルや専門知識を要するオントロジー構築には十分には適していない可能性があることがわかった。

Enrique ら[4]は、一般的な固有表現認識の教師なし学習と自動概念発見を用いて特定分野に依存する情報でオントロジーを拡張する手法を提案している。結果としてオントロジーの拡張を自動化するという点において高い性能が示された。

第3章 大規模言語モデルに基づくオントロジー

自動構築

マスク言語モデル(Masked Language Model)は自然言語処理のタスクの一つで特定の部分のテキストを隠し,その隠された部分を予測することで文脈の理解を学習するモデルである.本章では本研究の基盤となっている先行研究の説明とマスク言語モデルの説明,本研究で使用したモデルについて説明する.

3.1 LLM4OL

ここでは本研究の基盤となる LLMs4OL について説明していく. LLMs4OLは大規模言語モデル(LLM)を活用してオントロジーが学習の自動化を目指し,従来の手動によるオントロジー作成の課題を解決する

表 1 : LLMs4OL 基本的な要素

1	用語のタイプ分け	オントロジーを構成するための基本的な用語を含むセット.これらの用語はオントロジー内での概念のタイプやカテゴリーを表す.
2	概念のタイプ分け	用語の種類やカテゴリーを示すタイプ.例えば,「動物」や「植物」といった,概念を分類するための大まかなカテゴリが含まれる.
3	タイプの階層	概念のタイプ間の階層関係を定義するもの.例えば,「犬」は「動物」に属し,「動物」は「生物」に属するという階層構造である.
4	非階層的関係	階層関係とは異なる,例えば「関連する」「使用する」などの非階層的な関係を表すもので,オントロジー内でタイプ間にどのような関係があるかを定義する.
5	公理	オントロジー内で暗黙的な事実を明示化するための制約やルールである.例えば,特定の概念に必ず含まれる属性や,概念間の関係が満たすべき条件などを表す.

表 2：主要なタスク

A	用語タイプの発見タスク	LLMがテキストから用語を抽出し,それを適切なタイプ(概念)に分類できるかを評価する.このタスクでは,用語の意味を理解し,その用語がどのタイプに属するかを判断する能力が求められる.
B	タイプ階層発見タスク	概念タイプ間の「is-a」(階層的な)関係を発見する能力を評価する.例えば,「犬は動物である」という階層関係を抽出することである.このタスクでは,LLMが概念間の上位-下位の関係をどれほど正確に識別できるかが重要となる.
C	タイプ間の非階層的關係発見タスク	概念タイプ間の階層的でない関係(例えば,関連性や相互作用)を識別する能力を評価する.このタスクでは,LLMが「関係がある」「使用する」などの非階層的な関係をどのように発見するかが重要である.

新しい枠組み「LLMs4OL」を提案している. LLMs4OLは5つの基本的な要素を中心にしている(表1). このようなLLMs4OLはLLMsが従来のオントロジー学習に比べて,より効率的かつスケーラブルな方法で知識を抽出し,オントロジーを自動で構築出来るという仮説である.そこで先行研究ではこの仮説を実験するために3つの主要なタスクを定義し検証している(表2).

これらのタスクはマスク言語モデルを用いて行われる. 先行研究ではタスクAをWordNet, Geonames, UMLSから用語を利用している. WordNetでは,元のWordNetをもとにしたベンチマークデータセット「WN18RR」を使用して,事前に作成された訓練セットとテストセットに分割されており,このデータセットには40,943の用語が含まれ,用語間には18種類の関係があり,名詞,動詞,副詞,形容詞の4種類の用語タイプが存在している. オリジナルの検証セットとテストセットを統合して1つのテストデータセットとして利用している. Geonamesでは680種類の地理的カテゴリがあり,それらは9つの上位カテゴリに分類されている. 一方UMLSには約300万の概念がさまざまなソースから収録されており,

表：3 テスト結果

Task	Dataset	Zero-Shot Testing										
		BERT-Large	PubMedBERT	BART-Large	Flan-T5-Large	Flan-T5-XL	BLOOM-1b7	BLOOM-3b	GPT-3	GPT-3.5	LLaMA-7B	GPT-4
A	WordNet	27.9	–	2.2	31.3	52.2	79.2	79.1	37.9	91.7	81.4	90.1
	GeoNames	38.3	-	23.2	13.2	33.8	28.5	28.8	22.4	35.0	29.5	43.3
	NCI	11.1	5.9	9.9	9.0	9.8	12.4	15.6	12.7	14.7	7.7	16.1
	SNOMEDCT-US	21.1	28.5	19.8	24.3	31.6	37.0	37.7	24.4	25.0	13.8	27.8
	MEDCIN	8.7	15.6	12.7	13.0	18.5	28.8	29.8	25.7	23.9	4.9	23.7

それらは意味的な関係で結び付けられている。

先行研究で使用されたLLMは、BERT-Large, BART-Large, Flan-T5-XL, BLOOM-1b7, BLOOM-3b, GPT-3, GPT-3.5, LLaMA, GPT-4である。タスクAの評価には「k=1での平均適合率(MAP@1)」を使用しており、評価セットの用語で初期化されたプロンプトに対してLLMが出力した用語タイプの中で一番目に出力されたものの適合率を測定している。結果を図2に示す[3]。この図から、各データセットにおける最も高い評価であったLLMはWordNetでは91.7%のGPT3.5, Geonamesでは43.3%のGPT-4, NCIではGPT-4の16.1%, SNOMEDCT_USでは37.7%のBLOOM-3b, MEDCINでは29.8%のBLOOM-3bが1位であった。

本研究で扱うタスクAはマスク言語モデルを使用してオントロジー学習タスクを実行する方法を提案している。マスク言語モデルは、プロンプトを通じて与えられた文脈からかけている情報を予測する能力を活用してタスクに反応する。プロンプトは「[S] is a [MASK]」という形式で設計されている。ここでマスクされた部分を予測する形式で上位概念の抽出を試みる。

3.2 マスク言語モデル

最も広く知られているマスク言語モデルは BERT である。BERT[5]とは、2018 年に Google により発表された自然言語処理の手法である。Masked Language Model は、単語の双方向の文脈の理解を目的に行うタスクである。

入力文の一部の単語を[MASK]トークンに置き換え、この[MASK]トークンを予測するための学習を行う。マスク言語モデルは与えられたテキストから特定の単語や概念を抽出し、その単語や概念がオントロジー内でどの位置に属するのかを識別する時に活用する。オントロジーは、特定のドメインにおける概念や関係性を体系的に定義する構造を持つ。そのため、マスク言語モデルに概念間の関連性を学習させることで、用語のタイプを分類することができる。具体的には、テキスト内の単語をマスクして、モデルが文脈からその隠された単語を予測する。この過程では、マスクされた単語が表す概念がオントロジーにおいて、どのクラス、どの属性に該当するかを学習し、分類する。例えば、医療分野のオントロジーを構築する場合、モデルは「薬」や「病気」などの単語を文脈に基づいて予測し、それらを適切なカテゴリーに分類する。また、マスク言語モデルは、単語同士の関係性や、上位・下位概念、属性などの意味的特徴を理解し、オントロジー内の概念間の関連性を定義するための基盤を作る。

先行研究では BERT-Large, PubMedBERT, BART-Large, Flan-T5-Large, Flan-T5-XL, BLOOM-1b7, BLOOM-3b, GPT-3, GPT-3.5, LLaMA-7B, GPT-4 の 11 種類の LLM を用いて評価している。一方で、本研究では、BERT と GPT-3 のみを使用して評価した。BERT のモデルを一から学習させることは非常に時間とコストがかかるため、東北大学が公開している日本語 BERT モデル(cj-tohoku/bert-base-japanese)を使用する。

3.3 文脈を考慮した分類

マスク言語モデルが推論をする仕組みを説明する。マスク言語モデルは一部の単語が意図的に「マスク」された文章が入力されると、その文脈からマスクされた部分を予測することで推論を行う。本研究ではテンプレートを使って推論をおこなう。例えば表 4 のテンプレートを考える。モデルはこのテンプレートに基

表 4：例となるテンプレート

1	[MASK]を食べました
2	[MASK]をかける
3	昨日の夜、[MASK]で晩御飯を食べた。
4	晩ご飯に[MASK]を食べた

づいてマスクされた単語[MASK]を埋めるのに最適な単語を文全体から判断する. このテンプレートでは「昨日」, 「食べました」という情報から, 食べ物に関する単語を推測する. さらにこれらの情報から候補をいくつか生成し, 最も適切な選択肢を確率的に評価して, 選ばれた単語を出力する.

文脈を考慮した推論の利点は 2 つある. 1 つ目は, 曖昧な単語への対応ができることである. 例えば, 表 4 の 2 のテンプレートを使用して推論すると, 料理の話をしている場合は「ソース」という単語が推測される. また電話の話をしている場合は「電話」という単語が推測される. このように文脈によって同じ単語でも異なる意味を持つ単語でも異なる意味が推測可能である. 2 つ目は多様なテンプレートに対応できることである. 表 4 の 3, 4 のテンプレートの場合, 1 つ目の文章は「[MASK]で」という表現から, 「場所」や「手段」を推測する必要がある. また 2 つ目の文章は「[MASK]を」という表現から, 「食べ物」そのものを推測する必要がある.

さらに, これらのテンプレートに付加情報を加えることで推論の精度が向上する. その理由を 5 つに分けて説明する. 一つ目はモデルが文脈をより深く理解できることである. 入力されたテキストの文脈に基づいて隠された単語やフレーズを予測するが, 正確な予測が難しくなる. 付加情報を提供することで, モデルは隠された単語に関連するより広範囲な情報を利用できるため, 予測の精度が向上する. 表 4 の二つ目のテンプレートの場合付加情報なしだと「渋谷」や「浅草」など複数の可能性があり, モデルの予測が分散する. しかし「東京の観光地」という情報を提供すると, モデルが「浅草」や「東京タワー」などの関連度の高いワードを予測しやすくなる.

2 つ目は曖昧性のある文章を明確にすることである. 表 5 ではモデルが付加情報を利用することで, 複数の解釈が可能な場合でも, より適切な解釈をすることができる. 表 5 の二つ目の場合[MASK]に複数のアスリートの名前が候補として挙がるが, 付加情報として「水泳」というワードを追加すると「マイケル・フェルプス」などの水泳競技に関連する名前が選ばれやすくなる.

三つ目はドメイン知識の補強ができることである. 本研究で扱う東北大学が提供する日本語の BART モデル然り, 一般的なモデルは, 広範囲な知識を有しているが, 特定のドメイン(例:医療, 法律, 技術など)についての知識が不足していることがある. 付加情報を加えることで, モデルがそのドメインに特化した情報を

表 5：曖昧性，補強の例となるテンプレート

1	[MASK]は東京にある最も有名な場所の一つである
2	[MASK]は 2024 年のオリンピックで活躍しました。
3	[MASK]は抗生物質として使用される

利用できるようになる. テンプレートの三つ目ではモデルは「ペニシリン」や「アモキシシリン」などを予測するが, 他の候補が混ざる可能性もある. 付加情報として「細菌感染症治療」という言葉を追加するとより適切な抗生物質の候補を特定することができる.

付加情報は単語だけでなく文章でも提供することができる. 文章で提供することは単語の付加情報と比べると, より文脈を豊かにして, 曖昧性を解消して推論力を強化することができる. さらに, 柔軟に多様な情報をモデルに提供する手段として非常に有効である.

本研究では, 付加情報を提供する際にテンプレートの前に配置する.

第4章 実験

本研究では, 3 章で説明したマスク言語モデルを用いて行う実験について説明する. 具体的には, 3 章で説明したように, テンプレートを用意してターゲットの分野からデータに置き換え, 予測させて評価する. 本章では実際に用意したテンプレート, 評価に用いた正解ラベルを説明する.

4.1 一般知識ドメイン

4.1.1 テンプレート

先行研究では Geonames, Wordnet, NCI, MEDIN などの多様なドメインを研究対象として扱われていた. しかし, 本研究では特定のドメインに限定することでデータの性質や結果の解釈をより明確にするため, 地理情報を扱う Geonames のドメインに限定した. Geonames は, 地理情報を整理・統一し, 世界中のユーザーが利用できるようにするためのオープンなデータベースツールである. ここには, 各地名についての `geonamesid(ID)`, `name(地名)`, `asciiname(ASCII 表記の地名)`, `alternatenames(別名)`, `latitude(緯度)`, `longitude(経度)`, `feature class(大分類)`, `feature code(詳細分類)`, `country code(国コード)`, `cc2(複数の国にまたがる場合の追加国コード)`, `admin1 code(第 1 行政区分コード)`, `admin2 code(第 2 行政区分コード)`, `admin3 code(第 3 行政区分コード)`, `admin4 code(第 4 行政区分コード)`, `population(人口)`, `elevation(標高)`, `dem(デジタル標高モデル)`, `timezone(タイムゾーン)`,

表 6 : geonames のテンプレート

1. {name}は{country}にある地名です。{name}は[MASK]の一種です。
2. {name}は{country}にある地名です。{name}は[MASK]として知られています。
3. {name}は{country}にある地名である。{name}は[MASK]として知られている。
4. {name}は{country}にある場所である。{name}は[MASK]として知られている。
5. {name}は{country}にある場所である。{name}は[MASK]である。

modification date(最終更新日)が記述されている. テンプレートは先行研究で扱われたものと翻訳結果を元にして新たに作成した類似のテンプレートを併用した. このようなテンプレートを用意したのは翻訳の際に生じる特定の問題や偏りを軽減し, より多様なパターンを考慮するためである. 具体的には英語テンプレートをそのまま翻訳した場合, シングルクォーテーションの有無が8つのうちの半分を占めていた. テンプレートのバリエーションを持たせることでより広範囲な可能性をカバーできる.

実際に用意したテンプレートを表 6 に示す. {name}には実際の地名, {country}にはその地名が属する国の名前に置き換えてテンプレートを作る.

4.1.2 正解ラベル

一般知識ドメインの正解ラベルは, 先行研究で扱われていたテンプレートと同様, 機械翻訳で日本語にしたものに, 日本に適応するラベルを付け加えて作成した. この理由としてアメリカと日本では行政区分や文化が違うため偏りを減らすためである. 実際に使用した正解ラベルを表 7 に示す. ラベルの名前は各地域の特徴をもとに名前がつけられている. A は **Administrative**(行政に関する地域や組織を表して, 行政区域や政府機関に関連する場所を特定するために使用される), H は **Hydrological**(水域に関する場所を荒らして, 河川, 湖, 海などの水系に関する情報を特定するために使用される.), L は **Land Area**(土地に関する地域

表 7: 使用した正解ラベル

A	国,道,地域,県
H	川,小川,湖,運河,滝,湾,河川
L	公園,地域
P	都市,村,町,市,郡,区,
R	道路,鉄道
S	場所,建物,農場,駅,駅名,空港,漁港
T	山,丘,岩,峠,岬,島,
U	海底
V	森林, 荒地

を表して, 森林や草原, 山岳地帯など自然の陸地に関する場所を特定するのに使用される), **P** は **Populated Place** (集落や都市などの人が住んでいる場所を表して, 人口密度や人々の生活圏を示す地域を特定するのに使用される.), **R** は **Road/Transport** (道路や交通機関に関連する場所を表して, 道路, 鉄道, 空港などの交通インフラを特定するのに使用される), **S** は **Structure** (建物や施設に関連する場所を表して, 工場や学校, 病院などの構造物や施設を特定するのに使用される), **T** は **Topographic** (地形に関する特徴を表して, 山, 谷, 平野などの地球の表面に存在する物理的な特徴を特定するのに使用される.), **U** は **Underwater** (海底などの水中に存在する場所を表して, 海洋や湖底, 地下の環境に関する場所を特定するのに使用される), **V** は **Vegetation** (植生や森林に関連する場所を表して, 森林, 草原, 湿地帯など植物の生息する場所を特定するのに使用される) となっている.

4.2 専門知識ドメイン

4.2.1 化学分野における分析手法

本研究で扱う専門知識ドメインは化学分野における「分析手法」である.

分析手法とは, 物質やデータの性質, 構成, 状態を調べ, 特定の目的に応じた情報を得るための技術や総称である. 化学研究や工業的品質管理, 医療診断, 環境分析などさまざまな分野で使用されている. これには物質の構成要素や性質を特定する定性分析と, その量を正確に測定する定量分析が含まれ, さらに物理的特性を評価する物理的分析, 化学反応を用いた科学的分析, 生体分子を対象とする生物学的分析, 高度な装置を用いる機器分析に分類される. これらの手法は試料準備, 測定, データ解析というプロセスを経て行われ, 精度や正確性に基づいて評価される. 分析手法は基礎研究での知識の発見や応用研究腕の課題解決, 製品やプ

表 8 : 分析手法のオントロジー

1.	[S]. {name}は[MASK]のために使用される分析手法である
2.	[S]. {name}は分析装置であり、[MASK]の一種である。
3.	[S]. {name}は分析装置であり、[MASK]である。
4.	[S]. {name}は[MASK]の一種である。

表 9：テンプレートの前に配置する説明文

1.	走査電子顕微鏡は電子線を試料に当てた際に試料から出てくる電子の情報をもとに、試料の凹凸や組成の違いによるコントラストを得ることができる仕組みです
2.	走査コイルにより試料上で移動させて（電子線走査（scanning））、試料表面から放出される2次電子、反射電子が作るSEM像を取得する。
3.	走査電子顕微鏡（SEM）は電子線を試料表面に照射、x-y二次元走査し、表面からのさまざまな応答を用いて、表面構造の観察や組成分析などを行う装置である。




図 2：分析手法オントロジー

プロセスの品質管理, 法規制への対応といった多様な目的で活用されている。

4.2.2 テンプレート

専門知識ドメインではテンプレートの中に付加情報をテンプレートの前に配置して使うため最初の説明文も示す。説明文が入る場所を[S]で示す。さらに[S]も示す。[S]に入る分析手法の説明文は JAIMA が提供する分析機器の手引きから引用した。これらのテンプレートも {name} にタイプ分類したい単語を入れてテンプレートを作る。

4.2.3 正解ラベル

2 つ目の課題である分析手法オントロジーの構築について評価は図 2 に示されるように法造で表示されたオントロジーのグラフと照らし合わせながら行っていく [6]. 例えば評価対象として「電子線入射装置」を{**name**}に入力し, モデルの予測結果が「分析装置」. このように図 2 で定義されるような適切な上位概念が出力されれば成功とみなす. これは, 予測された概念がオントロジーの構造における適切な位置に基づいて, 正しい概念を正確に予想し, それをオントロジー内の適切な位置に関連づける能力を評価していく.

第5章 評価

この章では, 本研究で用いた評価手法の説明と, その評価手法を用いた評価結果を説明する.

5.1 評価手法

本研究では, 先行研究と同様の評価手法である **MAP** を用いた. **MAP** とは, 情報検索における「ランキング精度」の指標であり, 検索クエリに対して返されたアイテムの関連度を評価する.

AP は検索結果の中で正しい (関連性のある) アイテムがどれだけ含まれているかを示す指標であり, 検索をランク順に並べたアイテムの中で, 各順位で精度を計算し, それらを平均することで求める. 平均精度 (**AP**) は 1 つのクエリに対する精度の平均であり, **AP** の平均が **MAP** である. **Precision@k** とは検索結果の上位 **k** 件における正しいアイテムの割合を意味している. 具体的には次のように計算される.

$$Precision@k = \frac{\text{正解のアイテム数}}{k}$$

例えば, 検索結果の上位 5 位に関するアイテムが 3 つ含まれている場合, **Precision@5** は $3/5$ となる.

具体的には検索結果の順位を一つずつ確認し, 関連性がある場合にその順位までの累積精度を求める. 検索結果が以下のようになっていた場合, (関連性がある 1, ない 0) 各順位で, 関連するアイテムが見つかるたびに, その時点での精度を記録する. 最後に, 各順位における精度を平均する. **AP** の計算は次の通り

$$AP = \frac{1}{\text{関連したアイテムの数}} \sum_{k \in \text{関連性がある順位}} Precision@k$$

表 10 : MAP の例

順位	アイテム	関連性	Precision@k
1	アイテム A	1	$1/1=1.0$
2	アイテム B	0	$1/2 = 0.5$
3	アイテム C	1	$2/3 = 0.67$
4	アイテム D	1	$3/4 = 0.75$
5	アイテム E	0	$3/5 = 0.6$
6	アイテム F	1	$4/6 = 0.67$

表 10 のような例では, 関連性があるアイテムは 1 位, 3 位, 4 位, 6 位であるためこれらの順位における精度を平均する. よって **MAP@1** の値は **0.7725** となる **MAP** のメリットは高順位に関連性のあるアイテムが集中しているほど高いスコアが出るところである. 用語タイプ分類においてより上位であるものが第一候補であるため上位がよりスコアが反映されることで評価は高くなる.

5.2 Geonames の分類

ここでは Geonames を分類した結果を示す. 本研究では Geonames の日本に絞って実行した. まず 4.1.1 で示したテンプレートをを用いて BERT の日本語モデルで地名データ 1 件につき 1 つの予測を行った. データ全体を通じて一つ目のテンプレートでは 2401 種類, 二つ目が 1571 種類, 三つ目が 1297 種類, 四つ目が 1525 種類, 五つ目が 1206 種類の予測結果が得られた.

それぞれの MAP@1 の値は一つ目の結果が約 22%, 二つ目が約 17%, 三つ目が 18%, 四つ目が約 8%, 五つ目が約 4%であった.

今回, 予測される数値が総じて低いことがわかったため, 予測された結果が正解ラベルよりも下位の概念を予測していると仮定し, それぞれのテンプレートで正解ラベルに該当しなかった予測結果を同じテンプレートに入れてさらにタイプ分けを行った. この時, もう一度予測した結果がもし正解ラベルの中に含まれていれば予測は正しくいったとみなして, 評価した. その結果は, 一つ目のテンプレートが 0.3%増加, 二つ目のテンプレートが変化なし, 三つ目のテンプレートが変化なし, 四つ目のテンプレートが 0.1%増加した.

次に GPT を用いて分類した結果はテンプレートが 10%, 二つ目のテンプレ-

トが 2%, 三つ目のテンプレートが 0.1%, 4 つ目のテンプレートが 6%, 五つ目のテンプレートが 1% となった. やはり全体的に精度が芳しくないことが見て取れる. 上位のラベルを用いて予測させても正解ラベルにあまり合わなかったのは一度予測させたものと同じラベルが出力されていたからである.

5.3 化学分析手法の分類

ここでは, 4.2.2 で示したテンプレートを用いて, 予測させた結果を説明する. [S]に説明文を入れて{name}に分析手法に関する用語を入れる. BERT の日本語モデル, 表 8 で示した 1 番目のテンプレート, [S]に表 9 で示した 1 番目の補足文, {name}に「走査電子顕微鏡」を入れて予測させた場合の結果を表 8 の一行目, BERT の日本語モデル, [S]に表 6 で示した 1 番目の補足文, {name}に「走査電子顕微鏡」を入れた結果を表 8 の二行目に示す.

表 11 : Bert 日本語モデルを使用した分析手法予測結果

1	分析、解析、研究、、以下
2	これ、後者、上記、前者、手法

一行目では第一候補に「装置」ではないが「分析」という言葉が出てきており, 図 2 を見ると走査電子顕微鏡の二つ上の概念を指していることがわかる. 一つ上の概念ではないがある程度の予測ができていたことがわかる. 逆に二行目では「これ」や「後者」などの見当違いの予測がされていることがわかる.

次に GPT を用いて同じように表 5 で示した 4 番目のテンプレート, [S]には表 6 で示した 3 番目の補足文, {name}に「走査電子顕微鏡」を入れて予測させた場合の結果を表 5 の一行目, テンプレートが 3 番目, [S]には 3 番目の補足文, {name}には「走査電子顕微鏡」を入れて予測させた結果を表 6 の二行目に示した.

表 12 : 異なるテンプレートと補足文を用いた予測結果

1	顕微鏡、分析装置、撮影機器、解析装置、観察機器
2	高倍率、高解像度、表面分析、立体的、非破壊

一行目では第二候補に「分析装置」が出ており表 12 を見ると BERT よりも正確に上位概念を予測できていることがわかる. 逆に 2 行目を見てみると「高倍率」や「高解像度」などの予測が出てきており, 見当違いな予測がされているのがわ

かる.

第6章 考察

本章では, 5, 2, 5, 3 で提示した結果を受けて日本語データに対する LLMs4OL の手法がどれだけの精度があるのかの考察をする. 英語データに対する LLM4OL のタスク A(用語タイプ分類)と日本語データに対する LLM4OL のタスク A を比較すると表 10 のようになった. BERT と GPT の日本語の部分は五つのテンプレートの平均となっており, 英語の部分は 先行研究で扱われている BERT-Large, GPT3.5 の値となっている.

日本語とでここまで予測結果に差が生まれた要因について考察していく. 本研究においては, 日本語データと英語データを用いた地名の分類において, 予測結果に顕著な違いが見られた. それは日本語における地名の多くはその末尾に特徴的な要素を含んでいることが多い. 例えば「山」という文字が地名の末尾についている場合, その地名は主に山, もしくは山岳を指している場合が多く, 正解ラベルも「T」(Topographic: 地形に関する特徴を表している)になることが多い. このように地名の特徴が適切に保持され正解ラベルも正しいものであればモデルが正しい予測を行うことができると考えられる. 一方で, 逆に日本には末尾に「山」や「川」, 「崎」を含む地名でも正解ラベルが「P」(Populated Place: 集落や都市などの人が住んでいる場所を表している)であることがある. 例えば「和歌山」である. 日本人は「和歌山」と見た場合「和歌山県」を思い浮かべるが LLM の予測は「山」となっていた. これにより LLM は語尾の漢字に引っ張られることがわかる. そのためデータに加えて補正する情報を与えることが必要であると考えられる.

他に考えられる要因として, 予測結果がテンプレートに含まれる言葉と結びついてしまうという現象が挙げられる. 本研究において使用した BERT の日本語モデルで生成されたラベルの中で最も多く出力されたのは「地名」というラベルであった. その割合は 67010 件中 20579 件に達し, 全体の約 3 割を占めている.

表 13 : 日本語と英語の比較

	日本語	英語
BERT	14.0	38.3
GPT	7.0	35.0

この結果は今回分類したい正解ラベルよりも抽象度の高い上位概念に対応しており、現実的なオントロジーを構築するにあたって抽象度が高い上位概念であるため、役に立つには考えにくい。この現象として考えられるのはモデルがテンプレート内の「地名」という単語に影響を受けている点である。BERTのような事前学習モデルは、学習時に与えられたデータやテンプレートから影響を受ける。これを解決するためにはテンプレートを改良することが考えられる。

分析手法の分類において、補足文が予測する単語を説明文内で詳細に説明しても、テンプレート自体にドメインを絞り込むための用語が含まれていない場合、予測結果の精度が著しく低下することがわかる。これはドメイン固有の情報が不足している場合、予測モデルが正しい文脈を把握できず、一般的な解釈に偏る可能性があるためである。一方で、補足文がテンプレート内に含まれるドメインを絞り込むような用語と適切に組み合わせることで、予測精度が大幅に向上することがわかる。具体的には、補足文は曖昧な語句の意味を補強し、ドメインに関連した解釈をしやすくする役割を果たしており、これによりモデルがより正確に文脈を捉えることが可能になる。このことから補足文の設計においては、ドメイン特有の要素を強調するテンプレートと整合性を持たせることが重要であり、それが最終的な予測精度に大きな影響を与えられとされる。

第7章 おわりに

本研究では, 先行研究で行われていた **LLMs4OL** パラダイムの一つである用語のタイプ分類を日本語データで使用した場合での検証を行ない, **LLMs4OL** で扱われていないドメインでの適用の検証も行った. そして結果としては良い結果は得られなかったが翻訳を正確にしたり, テンプレートを変えたりすることで精度をあげられることを示した.

本研究の貢献は以下の通りである

日本語データへの適用

先行研究では英語データでのみ行われている **LLMs4OL** の **OL** タスクパラダイムの用語のタイプを日本語データへの適用を **BERT** と **GPT** を用いて試みた. その結果を受けて翻訳の精度を上げたり, 正解ラベルの定義を見直したり, テンプレートを改良することで精度を上げられることを提案した.

対象となるドメインでの適用

対象となるドメインは分析手法オントロジーであった. このドメインに対して用語のタイプ分類と同じように **BERT** と **GPT** のマスク言語モデルを用いて用語のタイプ分類を試みた. 結果はドメインを絞り込むテンプレートを使うことにより二つ上の上位概念ではあるが予測することが可能であることがわかった.

日本語データへの適用は日本語の文献やデータに基づいた知識体系をオントロジーとして整理することで, 異なる分野や業界間での情報共有を容易にするだけでなく, 国内における専門知識の効率的な管理や活用を可能にする. 特に学術分野や産業分野においては, 専門分野の概念が整理され, 異なるドメイン間での相互理解が深まる. また特殊なドメインでの適用は従来のキーワードベースの検索では困難だった, 高度な検索と情報抽出が可能になる点が重要である.

本研究では **LLMs4OL** の用語のタイプ分類までであったが階層構造の発見や非階層型関係の抽出についても考えることでより高度なオントロジー構築が可能になると考えられる.

謝辞

本研究を行うにあたって,熱心なご指導,ご助言を賜りました指導教官の村上陽平教授並びにアンペア先生,西村一球先輩,砂田界渡先輩,誠に感謝申し上げます.他にも森先輩や,元澤先輩などコーヒーで日々支えていただきありがとうございます.研究室の皆様にも多大な感謝申し上げます.

参考文献

- [1] 玉川 奨, 森田 武史, 山口 高平. :日本語Wikipediaからプロパティを備えたオントロジーの構築, 人工知能学会論文誌, 26巻, 4号, p.504-517 (2011).
- [2] 藤生 拓真, 岡崎 翔, 上西 康平. :事前学習済みLLMと小規模なドメインオントロジーを用いた生産ライン保全記録の構造化, 人工知能学会第二種研究会資料, 2024巻, SWO-063号, p.06-(2024).
- [3] BABAEI GIGLOU, Hamed; D’SOUZA, Jennifer; AUER, Sören. LLMs4OL: Large language models for ontology learning. In: *International Semantic Web Conference*. Cham: Springer Nature Switzerland, 2023. p. 408-427(2023)
- [4] ALFONSECA, Enrique; MANANDHAR, Suresh. An unsupervised method for general named entity recognition and automated concept discovery. In: *Proceedings of the 1st international conference on general WordNet, Mysore, India*. 2002. p. 34-43. (2002).
- [5] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova: BERT: Pre-training of deep bidirectional transformers for language understanding, arXiv:1810.04805v2 (2006).
- [6] 砂田 界渡, 來村徳信, 板倉 修一, 笹本 亮一, 細井 慎 : 無機材料分析手法の選択支援のためのオントロジーの構築とシステムの提案, 人工知能学会第二種研究会資料 セマンティックウェブとオントロジー研究会 SIG-SWO-064-03 (2024)

A.1 付録 1