

卒業論文

SharedPlans を用いた クロスドメイン QA システム

指導教官 村上 陽平 教授

立命館大学 情報理工学部
先端社会デザインコース 4 回生
2600220403-6

山内 瞭

2025 年度（秋学期）卒業研究 3（CH）
令和 8 年 1 月 30 日

SharedPlans を用いたクロスドメイン QA システム

山内 瞭

内容梗概

近年, Large Language Model (LLM) を用いた質問応答 (Question Answering; QA) システムが広く利用されている. これらは単一ドメインに閉じた質問には適切に回答できるが, 複数分野にまたがるクロスドメイン QA では, 異なるドメインの情報を段階的に結びつける推論が必要とされるため, 回答が困難となる. この課題に対し, 段階的な推論プロセスを組み込んだ Plan-and-Solve 型の単一エージェント手法や, 専門エージェントを組み合わせるマルチエージェント手法が提案されている. しかしながら, 多くの場合, 段階的な推論プロセスの計画立案や意思決定, 計画の実行管理を単一エージェントが担うため, このエージェントが誤った前提や幻覚的な出力 (hallucination) を生成した場合, 誤りが推論鎖に乗ったまま進行しやすい. その結果, 複数エージェントを用いたとしても推論プロセスの頑健性が得られず, 誤答や未回答につながりやすい.

そこで, 本研究では, 複数のエージェントが共通の計画を明示的に共有しながら協調作業を行う SharedPlans 理論を用いてクロスドメイン QA に回答する手法を提案する. 具体的には, 質問に対する回答生成を一つの共同作業として捉え, 複数の LLM エージェントが計画構築・調整・実行に関与する協調的なプロトコルを設計する. 本手法の実現にあたり, 取り組むべき課題は以下の 2 点である.

SharedPlans に基づく協調プランのスキーマ定義

出力の自由度が高い LLM エージェントを SharedPlans に基づいて連携させる場合, 各エージェントが共通計画を一貫して参照できるように, 計画を明示的な構造として表現・保持することが重要となる. そのため, 複数エージェントが計画の構造や前後関係を同一に解釈でき, 推論に必要な行為列を破綻なく共有できる協調プランのスキーマ定義が求められる.

SharedPlans 型マルチエージェント協調プロトコルの設計

SharedPlans 理論は, 各エージェントが目標や意図, 前提といった状態を共有した上で協調行動を行うことを前提としている. しかし, LLM エージェントにおいては, これらの状態を内部的に一貫して保持し, 実行の進行に応じて更新し続けることが難しい. その結果, 計画の作成, 合意, 修正, 実行といった協

調過程を通じて、どの情報が共有され、どの段階にあるのかが不明瞭になりやすく、協調行動全体を安定して進めることが求められる。

一つ目の課題に対しては、SharedPlans において協調行動を成立させるために必要な計画構造を、複数の LLM エージェントが共有可能なスキーマとして定義した。具体的には、トップレベル行為 α 、サブ行為列、前提・制約、および各サブ行為の担当を示す意図情報を、JSON スキーマとして構造化した。

二つ目の課題に対しては、SharedPlans 理論が想定する意図や前提の共有を、LLM エージェントの内部心理状態として直接の管理が難しい点を踏まえ、協調に必要な状態を外在化して扱う共通計画を用いた協調プロトコルを設計した。本研究では、相互信念そのものをエージェント間で保持・共有することは行わず、共通計画、各エージェントの計画への合意／不同意、および実行結果の履歴を共有状態として明示的に管理する。具体的には、計画作成、合意形成、不同意理由に基づく修正と再合意、および計画に沿った逐次実行と結果共有を段階的に行うことで、前提と進捗の整合を保ちながら協調行動を進められるようにした。本研究では、複数の Wikipedia 文書をまたいで根拠を統合し、段階的推論で答える QA データセットである HotpotQA をクロスドメイン QA のベンチマークとして用いて評価を行い、提案手法の有効性を検証した。貢献は以下の通りである。

SharedPlans に基づく協調プランのスキーマ定義

共通計画を JSON スキーマで構造化し、操作をサブアクションの挿入に制約することで、計画の前後関係や依存関係が破綻しにくい共有基盤を提供した。その結果、複数エージェントの関与下でも行為列が安定し、実行可能な協調プランの維持に貢献した。また、提案手法からプラン共有のみを除いた（GPT 評価 44.5%）アブレーションに対し、提案手法は 9.5% 高く、プラン共有の重要性が示された。

SharedPlans 型マルチエージェント協調プロトコルの設計

本研究では、共通計画に基づく合意形成・修正を含む協調プロトコルを実装し、シングルのエージェントおよび共有計画を用いないマルチエージェント手法と比較評価した。評価は GPT による同一基準の採点で行い、ドメイン限定条件下で提案手法は 54% と最も高いスコアを示した。さらに、提案手法から合意フェーズを除いた手法（34.5%）に対しては 19.5% の向上を確認した。以上より、共通計画に基づく段階的な合意・修正・実行が、複数ドメイン情報の統合と部分正解の生成を促進することが示唆される。

Cross-Domain QA Using SharedPlans

Ryo Yamauchi

Abstract

In recent years, LLM-based question answering (QA) has become widespread. While these systems perform well on single-domain questions, cross-domain QA remains challenging because it requires stepwise reasoning that links evidence across multiple fields. Prior work includes Plan-and-Solve single-agent methods with an explicit planning stage and multi-agent approaches that combine specialized agents. However, in many settings, planning, decision-making, and execution control are effectively centralized in a single agent, making the overall reasoning process fragile. When that agent produces incorrect premises or hallucinated facts, the error can propagate through the reasoning chain. As a result, even multi-agent systems may fail to achieve robust reasoning, leading to more incorrect or unanswered outputs.

This study proposes a SharedPlans based method for cross-domain QA, where multiple agents explicitly share a common plan. We treat answer generation as joint work and design a cooperative protocol in which multiple LLM agents participate in plan construction, adjustment, and execution. This method requires addressing to challenges.

Schema definition for collaborative plans based on SharedPlans

SharedPlans requires a cooperative-plan schema that multiple LLM agents can share consistently. When agents with high output freedom collaborate under SharedPlans, a system needs an explicit plan representation that every agent can reference consistently. Therefore, a schema must allow agents to interpret plan structure and ordering relations consistently and to share the required action sequence without breakdown.

Design of a SharedPlans-based Multi-agent Cooperation Protocol

A SharedPlans style multi-agent cooperation protocol must stabilize the collaboration process. SharedPlans assumes that agents share goals, intentions, and preconditions. LLM agents struggle to maintain such states internally and to update them as execution progresses. This limitation can make it unclear what information agents share and which phase the

collaboration has reached across planning, agreement, revision, and execution. A protocol must therefore support stable cooperative progress.

For Challenge 1, we define a plan structure necessary for SharedPlans based cooperation as a schema that multiple LLM agents can share. Specifically, we structure a top-level action α , a sequence of subactions (recipe), preconditions and constraints (context), and intention information that assigns responsibility for each subaction, and we represent them as a JSON PlanDoc.

For Challenge 2, we design a cooperation protocol that externalizes shared state through a common plan. Rather than maintaining mutual belief across agents, the system explicitly tracks the shared plan, each agent’s agreement or disagreement, and an execution-history log. The protocol proceeds through plan creation, agreement, revision driven by disagreement reasons and re-agreement, and stepwise execution with result sharing. This design preserves consistency between preconditions and progress while supporting stable cooperation. We evaluate the proposed method on HotpotQA, a multi-hop question answering benchmark that requires integrating evidence across multiple Wikipedia documents, and confirm its effectiveness. The contributions of this work are summarized as follows.

Stabilization of cooperative plan generation based on SharedPlans

We define PlanDoc, a shared plan schema that represents the top-level action, subactions, context, and responsibility assignments. By restricting edits to inserting a single subaction with its position, PlanDoc preserves ordering and dependencies, helping maintain executable plans under multi-agent participation. Removing plan sharing drops GPT-based evaluation to 44.5%, showing a 9.5% gain from explicit plan sharing.

Design of a SharedPlans style multi-agent cooperation protocol

We implement a shared-plan protocol that performs agreement, disagreement-driven revision, and stepwise execution, and compare it with single-agent and non-shared-plan multi-agent baselines. Under domain-restricted settings, the proposed method achieves the highest GPT score (54%); removing the agreement phase reduces it to 34.5%, indicating a 19.5% gain from agreement and revision.

SharedPlans を用いたクロスドメイン QA システム

目次

第 1 章 はじめに	1
第 2 章 関連研究	3
2.1 クロスドメイン QA	3
2.1.1 シングルエージェント	3
2.1.2 マルチエージェント	4
2.2 SharedPlans	5
第 3 章 SharedPlans に基づくクロスドメイン QA	7
3.1 システム全体構成	7
3.2 LLM エージェントの設計	8
3.3 SharedPlans のスキーマ	9
3.4 SharedPlans 準拠プロトコル	11
3.4.1 プラン構築フェーズ	11
3.4.2 合意フェーズ	13
3.4.3 修正フェーズ	14
3.4.4 実行フェーズ	15
第 4 章 実験	17
4.1 実験設定	17
4.1.1 実験データセット	17
4.1.2 ベースライン	17
4.1.3 評価指標	19
4.2 実験結果	20
4.2.1 2 ドメイン	20
4.2.2 5 ドメイン	20
4.2.3 10 ドメイン	21
4.3 アブレーションテスト	22
第 5 章 考察	23
5.1 ドメイン数に応じた提案手法の特性	23

5.1.1 各ドメインにおける解答例	23
5.1.2 ドメイン数の増減による回答精度への影響.....	24
5.2 ベースラインとの比較	25
第 6 章 おわりに	26
謝辞	28
参考文献	29
付録	30
A.1 提案手法ドメイン数ごとの実行例	30

第1章 はじめに

近年, LargeLanguageModel (LLM) を用いた自然言語処理技術が急速に発展し, 百科事典的知識を用いた質問応答 (QuestionAnswering; QA) システムが広く利用されるようになってきている. これらのシステムは, 大量のテキストから獲得した知識をもとに, 自然言語で与えられた質問に対して, 人間が理解しやすい形で回答や思考過程を生成できる点に特徴がある. 検索エンジンや対話型エージェントを通じて, 日常的な情報検索から専門的知識の参照まで, LLM ベースの QA は社会のさまざまな場面に浸透しつつある.

一方で, 人物, 地理, ビジネスなど複数の分野にまたがるクロスドメイン QA では, 単一の事実想起だけでは足りず, 異なるドメインに属する複数の情報を段階的に結びつけて推論することが求められる. 例えば, 「人物の出身地」と「地域の出来事」を組み合わせる問題や, 「作品」「作者」など複数観点をまたぐ問題では, 中間的な問いを立てながら知識を統合していくプロセスが必要となる.

このようなタスクに対して, 単一の LLM が思考過程を生成する Plan-and-Solve といった手法が提案されている. また, 専門分野ごとのエージェントを組み合わせるマルチエージェント型手法も登場しており, 性能向上を図る試みが進められている. しかし多くの手法では, タスク分解や情報収集は行われるものの, どのサブアクションを誰がどの順序で担当するかといった計画構造を, 複数エージェント間で明示的に共有・更新する仕組みは十分ではない. その結果, 計画立案や最終的な意思決定が単一のエージェント (単一モデル, あるいはルータ/マネージャ役) に集約されやすく, 推論の統合が単一点に依存しやすい構造となる. この構成では, 統合役が誤った前提やハルシネーションを取り込んだ場合でも, 他エージェントが計画や前提を参照して検証・修正する回路が弱く, 誤りが推論鎖に乗ったまま進行しやすいという課題がある.

一方, 人間のグループにおける協調では, 各メンバが専門や視点に基づいて計画構築に関与し, 役割分担や順序を相互に調整しながら決めていく. すなわち, 計画が共有された上で前提や進捗を点検し, 必要に応じて計画を更新しながら目的達成を図る. しかし既存の LLM ベースの QA システムでは, 計画そのものを共同で構築・維持するプロセスが十分にモデル化されているとは言い難い.

本研究が対象とするのは, 人物・地理・エンターテインメント・ビジネスなど複数ドメインの知識を統合して推論するクロスドメイン QA である. このような

問題に対しては、単一のエージェントにすべてを担わせるのではなく、各ドメイン知識を持った複数エージェントが共通計画を共有し、構築・点検・更新を伴いながら協調的に推論する枠組みが適していると考ええる。

以上の背景から、本研究では、協調行為の理論的枠組みである SharedPlans を導入し、クロスドメイン QA におけるタスク分解と協調推論のプロセスを明示的にモデル化し、その優位性を図ることを目指す。SharedPlans は、グループが共同で目的を達成する際の「トップレベル行為」、それを構成する「レシピ」、状況や前提条件を表す「コンテキスト」、およびメンバの意図などを通じて協調を記述する枠組みであり、これを LLM マルチエージェントに適用することで、人間のグループ協調に近い振る舞いを実現できる可能性がある。

本研究の目的は、SharedPlans 理論に基づき、複数の LLM エージェントがそれぞれの観点から計画構築に関与しながら協調してクロスドメイン QA に回答する枠組みを構築し、その有効性と振る舞いを明らかにすることである。具体的には、質問に対するトップレベル行為 α を「正しい回答の生成」として定義し、これを複数のサブアクションからなるレシピ R_α とコンテキスト C_α に分解したうえで、ドメイン別エージェントが役割にもとづいてサブアクションを提案・分担する協調モデルを設計する。

さらに、プラン構築、タスク追加、合意形成、タスク実行、最終回答生成からなる SharedPlans 準拠のプロトコルを実装し、エージェント間のやりとりやレシピの変化を構造化ログとして記録することで、「どのように計画が洗練され、どのエージェントがどの部分に貢献したのか」を後から分析できるようにする。そして、代表的なクロスドメイン QA ベンチマークである HotpotQA を用いて、単一エージェント手法などと比較し、回答精度・プラン構造の観点から SharedPlans 型マルチエージェントの特徴と利点・限界を評価する。

本論文の構成は以下の通りである。第 2 章では関連研究として、単一エージェント手法およびマルチエージェント型手法の概要を整理し、SharedPlans 理論の位置づけを述べる。第 3 章では提案手法として、トップレベル行為 α 、レシピ R_α 、コンテキスト C_α の定義、エージェント設計、および協調プロトコルを説明する。第 4 章では HotpotQA による実験設定、評価指標、および比較結果を示す。第 5 章では評価結果にもとづき、有効性、エージェント数やタスク分担と性能の関係、限界と改善の方向性を考察する。最後に第 6 章でまとめと今後の課題を述べる。

第2章 関連研究

2.1 クロスドメイン QA

クロスドメイン質問応答 (cross-domain Question Answering) は、人物、地理、ビジネスなど複数の分野にまたがる知識を統合して解答を導くタスクである。この種のタスクでは、単一の事実を想起するだけでは不十分であり、質問文の意図に沿ってどの事実をどの順に確認するかというタスク分解を行い、複数ドメインの情報を段階的に結びつけながら推論を進める必要がある。本節では、このようなクロスドメイン QA に対する既存の LLM ベースのアプローチを、単一エージェントによる手法とマルチエージェントによる手法に分けて整理する。

2.1.1 シングルエージェント

近年の質問応答システムでは、大規模言語モデル (LLM) に対して Chain-of-Thought (CoT) [1]や Plan-and-Solve[2] といったプロンプトを与え、モデル自身に「まず考え方を整理し、その後に答えを出す」手続きを明示させる手法が広く用いられている。CoT では、単一のエージェントが自然言語で推論過程を逐次生成し、その流れに沿って最終回答を導く。Plan-and-Solve では、最初に問題の理解や解決ステップの列挙を行い、続いてその計画を参照しながら回答を生成するという二段階構成をとる。このような手法は、LLM の「一発回答」に比べて推論の透明性が高く、人間が途中の思考を確認しながら信頼性を判断できる点で、実務的にも有用な枠組みとなっている。

しかし、本研究が対象とするクロスドメイン QA のように、人物・地理・歴史・ビジネスなど複数の領域にまたがる知識を組み合わせる必要がある場面では、シングルエージェント型には以下のような限界がある。

シングルエージェントでは計画の立案から最終的な意思決定までが単一に集中しているため、「別の視点をもったエージェントが途中でプランに口を挟む」「あるドメインの専門家が、他のドメインの専門家と相談しながらタスクを再分担する」といった、複数エージェント間の協調プロセスそのものをモデル化したり比較したりすることができない。その結果、一度ミスリードとなる前提や解釈が入り込むと、同じエージェントの視点のまま推論が進行してしまい、中間段階で「本当にこの方向性でよいか」を別の立場から検討する余地が少ない。

このような構成では、途中の誤った推論や根拠の薄い仮定を、異なるエージェントどうしのやりとりによって修正することが難しく、ハルシネーションや不要な脱線がそのまま最終回答に反映されるリスクを十分に抑えきれないと考えられる。

2.1.2 マルチエージェント

シングルエージェント型の限界を補う試みとして、近年は複数の LLM を組み合わせたマルチエージェント型の質問応答手法も提案されている。[3] これらの手法では、それぞれに少しずつ異なる指示や知識の前提を与え、「人物に詳しい役」「地理に詳しい役」など、得意分野の異なるエージェントを用意する構成がある。クロスドメインな質問に対して、複数のエージェントがそれぞれの視点から情報を補い合うことで、単一モデルよりも安定した推論や高い回答精度を目指す点に特徴がある。

代表的な構成のひとつは、「ルータ」「マネージャ」と呼ばれるまとめ役のエージェントを中央に 1 つ置き、このエージェントが他の専門エージェントを呼び分ける方式である。ルータはまずユーザからの質問を受け取り、「これは人物中心の話なので People 系のエージェントを呼ぶべきだ」「ここは地理情報の確認も必要なので Geography 系も追加で呼ぶべきだ」といった判断を行う。選ばれた専門エージェントは、ルータから渡されたサブタスクや質問に応答し、その結果をふたたびルータに返す。ルータは複数のエージェントから集まった中間結果を統合し、どの情報を採用するか、どのような形で最終回答とするかを決定する。こういった手法は、専門エージェントとルータ役を組み合わせることでクロスドメイン QA に対応するアプローチの一例と位置づけられる。

この種のマルチエージェント構成の利点は、「どのドメインの知識を使うべきか」という観点をシングルエージェントより明示的に制御できる点にある。ルータが質問文や中間結果を見ながら、「今は人物情報が重要」「次は地理や組織の関係を確認すべきだ」といった判断を行うことで、必要な専門エージェントを優先的に呼び出せる。また、専門エージェント側も、自分に与えられた役割に沿って情報を整理すればよいため、ペルソナ設計と組み合わせることで「人物の経歴」「地理的な包含関係」など、特定の観点到特化した出力を引き出しやすい。

一方で、計画の流れや最終的な意思決定の中心は、依然としてルータ側に置かれていることが多い。多くの場合、専門エージェントは「呼ばれたときに自

分の得意分野について回答する」役割にとどまり、「どのような全体計画のもとでそのタスクが自分に割り当てられているのか」「そのタスクを完了すると全体の計画のどこが満たされるのか」といった情報は、ルータの内部ロジックの中に埋め込まれたままである。つまり、エージェント自身の側から見た意図や共通の計画を明示的に取り扱うモデルにはなっていない。

このように、既存のマルチエージェント手法は、シングルエージェントに比べて「専門性の異なるモデルを組み合わせる」という点では前進しているものの、協調の設計はルータやアグリゲータの実装に依存していることが多い。加えて、人間のグループ活動のように、「共有された計画の上に、複数のエージェントが意図と役割をもって参加している」状態を直接表現しているわけではないということがわかる。

2.2 SharedPlans

SharedPlans[4]は、Grosz and Kraus によって提案された協調行為の形式的モデルであり、複数のエージェントが共同で一つの目標を達成するときに、どのような計画構造と意図を共有しているべきかを記述する枠組みである。この理論では、まずグループ全体が目指すトップレベル行為 α （「夕食を作る」「会議の準備を完了する」など）を置き、それをより小さなサブアクション列レシピ R_α と、利用可能な資源や前提条件などをまとめたコンテキスト C_α に分解して表現する。さらに、各サブアクションについて「誰がその行為を自分の責任として引き受けるつもりか」を表す Int-To や、「あるエージェントが、他のエージェントにその行為を期待している」ことを表す Int-That、そしてそれらを支える共同コミットメントや相互信念といった心的状態を明示的に扱う点に特徴がある。

このとき重要なのは、SharedPlans が単に「タスクの並び」を記述するだけでなく、「そのタスク列を誰がどの意図で引き受けているのか」まで一体として捉えている点である。グループは、トップレベル行為 α をどのようなサブアクションに分解するか、それぞれのタスクを誰が担当するか、そしてその計画をどこまでの粒度で共有し、どの程度コミットしているかを段階的に整えていく。特に、計画の具体性と共有の度合いに応じて、まだ計画が粗く一部しか共有されていない段階を PartialSharedPlan (PSP)、サブアクション列と役割分担が十分に具体化され、全員がその計画に共同コミットしている状態を FullSharedPlan (FSP) として区別する考え方は、人間のグループ活動をよく捉えている。すな

わち SharedPlans によれば、「どのようなタスク分解のもとで」「誰がどの部分を担当し」「どの段階でグループとしてその計画を受け入れたのか」を、計画構造と心的状態の両面から理論的に議論できる点が大きな利点である。

一方で、原典の SharedPlans は、エージェントの信念や意図を論理式で記述する協調の条件の理論として提示されており、「どのような性質を満たしていれば協調していると言えるか」を明らかにすることに主眼が置かれている。そのためシステム実装の観点から見ると、 $\alpha \cdot R_\alpha \cdot C_\alpha \cdot \text{Int-To/Int-That}$ をどのようなデータ構造として表現し、どのタイミングでどのように更新するか、あるいは、どのようなメッセージ交換プロトコルによって合意形成や役割の再調整を行うかといった具体的なアルゴリズムや実装指針までは直接には与えていない。言い換えれば、SharedPlans は協調している状態そのものをどう特徴づけるかを与える規範的な理論であり、その状態に到達するために実際のシステムがどのように振る舞うべきかを逐一規定する手続き的プロトコルではない。

さらに、SharedPlans の枠組みはどのような $\alpha \cdot R_\alpha \cdot C_\alpha \cdot \text{Int-To}$ が備わっていればよいかを抽象的に述べる一方で、自然言語で与えられたタスクから R_α をどのような手順で構成するのか、どのような対話や交渉を通じて PSP から FSP へ移行するのかといった手続き的側面についてはほとんど触れていない。たとえば、サブアクションの抜け漏れに気づいたエージェントがどの条件でタスク追加を提案すべきか、複数エージェントの提案が競合した際にどのように調整すべきか、計画の一部が誤りと判明した場合にどこまで遡って再計画するかなどの運用ルールは、理論の外部に委ねられている。そのため、SharedPlans を大規模言語モデルベースに直接適用しようとする、心的状態ロジックとして与えられた条件と、実装上扱える情報（プロンプト・出力・ログ）との間にギャップが生じる。本研究は、このギャップに着目し、SharedPlans の枠組みを参照しつつも、LLM マルチエージェントが実際に扱いやすい軽量なスキーマと協調プロトコルへと再構成することを目指すものである。

第3章 SharedPlans に基づくクロスドメイン QA

3.1 システム全体構成

本システムは、クロスドメイン QA ベンチマークから与えられる質問を入力とし、複数の LLM エージェントが SharedPlans の枠組みに従って協調的にタスク分解・推論を行うことで、最終的な回答を生成する。処理の流れは、大きく次の 5 つの要素から構成される。

- 入力・前処理モジュール
クロスドメイン QA ベンチマークから質問文を読み込み、内部表現に変換する。
- LLM マルチエージェント群
人物、地理、ビジネスなどのドメインごとに設計された複数の LLM エージェントからなり、各エージェントは共通の SharedPlans ポリシーと、ドメインに応じたペルソナをもつ。その設計の詳細は 3.2 節で述べる。
- SharedPlans データスキーマ
トップレベル行為 α 、レシピ R_α 、コンテキスト C_α 、Int-To/Int-That、コミットメントを JSON 形式のデータスキーマとして表現する。これにより、計画と協調過程を構造化して扱う。各要素の定義は 3.3 節で詳述する。
- SharedPlans 準拠プロトコル
本システムにおける SharedPlans 型マルチエージェントの処理プロトコルは、次の 4 段階から構成される。
 1. プラン構築フェーズ
質問文とトップレベル行為 α をもとに、各エージェントが自らの専門性に基づいてレシピ R_α にサブアクション候補を追加し、暫定的なプランを形成する。
 2. 合意フェーズ
形成された暫定プランについて、各エージェントが妥当性を評価し、全員の合意が得られれば、そのプランを実行用の「合意済みプラン」として採用する。
 3. 修正フェーズ(非合意時)
合意に至らなかった場合は、不同意の理由を手掛かりにサブアクション

の追加・修正を行い、プランを調整したうえで再度合意を試みる。

4. 実行フェーズ

合意済みプランに従って、各エージェントが担当サブアクションを順に実行し、外部知識の参照結果や中間推論を実行履歴として蓄積する。最終的な回答はこの実行履歴に基づいて生成される。

- 実行ログ・評価インタフェース

各フェーズにおけるプラン構造、エージェントの入出力、中間結果、実行履歴から得られた最終回答などをログとして記録し、第4章の実験と第5章の考察に用いる。

3.2 LLM エージェントの設計

本研究のマルチエージェントは、基盤となる LLM モデル自体は共通であるが、

(1) SharedPlans に基づく共通の行動規範

(2) ドメイン固有の専門性を与えるペルソナ

を組み合わせることにより、異なる視点をもつ仮想的な専門家として振る舞うように設計した。また、本研究におけるトップレベル行為、レシピ、コンテキスト、意図 (Int-To/Int-That)、コミットメントといった概念は、SharedPlans に準拠しており、これをクロスドメイン QA 向けに具体化したものである。共有ポリシーは、すべてのエージェントに共通して与えられる指示の集合であり、SharedPlans 理論に基づく協調の枠組みを規定する。実装上は、次のような英語のシステムプロンプトとして定義し、全エージェントに共通して図 1 のように付与している。

ここで、 α はグループとしてのトップレベル行為、 R_α はその行為を構成するサブアクション列、 C_α はその実行に関する前提・制約を表す。Int-To/Int-That はそれぞれ「自分が行うつもり」の行為」「他のエージェントが行うと期待する行

```
"You are members of a SharedPlans multi-agent system collaborating to achieve a common goal defined by alpha."
"Shared Policy — SharedPlans (Grosz & Kraus, 1996)"
"<Core objects:>"
"-  $\alpha$ : top-level group action (goal)."
"-  $R_\alpha$ : recipe = subactions with partial order/dependencies."
"-: context/constraints (resources, preconditions, environment, norms)."
"- Int-To(x): x intends to perform subaction (ownership)."
"- Int-That(x,by y): x expects y will perform subaction (dependency; not a command)."
-略-
)
```

図 1 Shared Plans Policy プロンプト

Your Name: PeopleAG
You are specialized in people/biographical knowledge.
Scope (examples, not exhaustive):
- Official titles/positions and time periods.
- Affiliations/employment/memberships and notable roles.
- Name variants/aliases, notable works, major awards/honors.

図 2 PeopleAG のペルソナプロンプト

為」に対する意図を表し、グループ規範として、共通の目標・役割・計画状態への共同コミットメントと役割の明確化を要求している。

このように、共有ポリシーは「エージェントが SharedPlans 構造と意図表現をどのように扱うべきか」を定めるものであり、マルチエージェント全体として一貫した協調行動を保証する役割を果たす。

一方で、ペルソナは各エージェント固有の専門性と視点を規定するものであり、同じ共有ポリシーとモデルのもとでも多様なタスク提案や解釈が生まれるようにするための仕組みである。ペルソナはシステムメッセージとして与え、例えば PeopleAG に対しては図 2 のように与えた。

このように、各エージェントは SharedPlans に基づく共有ポリシーにより共通の協調ルールに従いつつ、ペルソナによって「どのような事実に注目し、自分の専門分野がトップレベル行為の達成にどのように貢献しうるのかを推論し、どのサブアクションを積極的に引き受けるか」が変化する。その結果、単一エージェントでは得にくい、複数ドメインからの視点をもった計画構築と推論過程を実現できる。

3.3 SharedPlans のスキーマ

本研究では、SharedPlans におけるトップレベル行為 α 、レシピ R_α 、コンテキスト C_α 、および各エージェントの意図 (Int-To) を LLM で行うにあたり、動的にかつスムーズに実行を行うための SharedPlans 準拠スキーマを、JSON 形式のデータ構造として実装した。このスキーマを main 関数側からエージェントに対して順番に回しながら、Plan の構築を図っていく。スキーマは図 3 のように定義した。


```

{
  "question": int, // 問題識別番号
  "alpha": "Generate answer this question 「{question}」", // グループ全体で達成すべきトップレベル行為
  "recipe":
  [
    {
      "act": "string", // αを達成するためのサブアクション
      "context": "string" //当該サブアクションの制約・前提条件
    }
  ],
  "intentions":
  [
    {
      "agent": "string", // このサブアクションを引き受けるエージェント名
      "action": "string" // エージェントが Int-To を持つサブアクションでactと同一
    }
  ],
  "context": "Use your domain information to achieve alpha with team agents" // トップレベル行為の制約・前提条件
}

```

図 3 Plan スキーマ

1. Question と alpha

question はベンチマーク上の問題番号であり，ログ解析や評価スクリプトから特定の質問・プランを参照するための安定した識別子として用いる．一方 alpha には，自然言語の質問文を埋め込んだ文字列を格納し，「与えられた質問に対する短い自然言語回答を生成する」というトップレベル行為 α を明示している．SharedPlans の観点では，alpha が「グループとして共有される最上位の目的」，question が「ベンチマーク上のインスタンス ID」という役割分担になっている．

2. Recipe: サブアクション列 R_α

recipe は，トップレベル行為 α を達成するためのサブアクション列 R_α を表し，各要素は $\{\text{"act":str, "context":str}\}$ からなる．act は「WorldviewEntertainment が製作した 2015 年の作品を特定する」のような 1 ステップ分の行為を表す短いラベルで，実装上は 1 行の英語フレーズで記述している．context はその行為が何のために必要か，どのような情報・前提に基づいて実行すべきかを述べるテキストであり，実行結果は含めず「計画段階での意図」に限定している．このように recipe は，「クロスドメイン QA をどのような観点のステップに分解したか」を後から追跡するためのプランの骨格として機能する．

3. Intention : Int-To による役割割当

Intentions は，SharedPlans における Int-To（誰が何を行う意図をもつか）を表すリストであり，各要素 $\{\text{"agent":str, "action":str}\}$ が，サ

ブアクション内容と担当エージェントを表す. ここでの action は recipe に記載された act と対応しており, 「どのサブアクションをどのエージェントが所有しているか」という ownership を明示する. 実装では recipe が更新されるたびに対応する intentions も更新し, 実行フェーズでは intentions を参照して「どのステップをどのエージェントに実行させるか」を制御している.

4. Context: プラン全体のコンテキスト C_α

context は, プラン全体に共通するコンテキスト C_α を表すフィールドであり, 本研究では "Use your domain information to achieve alpha with team agents" という文字列を格納している. これは, 「各エージェントが自分のドメイン知識を用い, チームとして協調しながらトップレベル行為 α の達成を目指す」という全体方針・前提条件を簡潔に与えるものである. 各サブアクションのコンテキストが「個々の行為に固有の目的・依存関係」を示すローカルな文脈であるのに対して, Plan["context"] は「ドメイン分担されたエージェントが協調して α を目指す」というシステム全体の環境・姿勢を共有する役割を担っている.

3.4 SharedPlans 準拠プロトコル

本節では, 3.3 節で定義した SharedPlans データスキーマに基づき, 本システムにおいて, 共通プランを管理する制御部が, プランの構築・合意形成 (評価)・修正・実行をどのように行うかを示す. 図 4 に, 提案手法の全体フローと各 LLM エージェントのインタラクションを示す. 提案手法では, 複数の LLM エージェントが共通のプラン文書 (PlanDoc) を共有し, 各フェーズでこの文書を参照・更新しながら協調的に推論を進める.

3.4.1 プラン構築フェーズ

プラン構築フェーズは, 本システムにおける Shared Plans 型協調の起点となるプロセスであり, 「 α を達成するための具体的な推論ステップ列」を複数の専門エージェントが共同で生成する段階である. 本フェーズの開始時点では, 制御部がトップレベル行為 α と空のレシピおよび担当表を含む初期プラン文書 (PlanDoc) を生成し, これを全エージェントに共有する. 以降, 制御部は各エージェントを順に呼び出し, その時点の PlanDoc を入力として与えることで, プラン構築を段階的に進める.




図 4 SharedPlans プロトコル

各専門領域に対応する複数の LLM エージェントは、「自分が担当できる部分のサブアクションを追加し、それ以外には手を出さない」という設計原則のもとで共通計画の拡張に関与する。エージェントがサブアクションを追加した場合、制御部はその更新結果を PlanDoc に反映し、次のエージェントへと受け渡す。このようにして、プラン文書は制御部によって一元管理されつつ、複数エージェントの提案が逐次的に統合される点に特徴がある。

ここで各サブアクションは、当該エージェントが「自分は何を行うつもりか」を明示する意図 Int-To の具体的な実行単位として位置づけられている。

その際、PlanDoc に付随する context は、当該サブアクションの前提条件・制約・依存関係、およびそのステップで得るべき成果物を簡潔に記述する欄として用いる。これにより、各ステップは「何をいつ実行可能で、どの情報を得るべきか」が明示された単位として、プラン文書上に記録される。

このとき、プロンプトではエージェントに対して次の点のみを明示的に指示している。まず TASK では、「共有プランを読んだ上でサブアクションを追加するかどうかを自分で判断すること」と指示することで、とりあえず何かを足すのではなく、追加しない選択も含めた慎重なプラン拡張を促している。RULES では、これを支えるために、

- 自分のドメインで実行できるサブアクションのみを追加する
- すでにカバーされている内容は繰り返さず、新しい情報や前提推論だけを足す
- ACT で新しい固有名詞を導入して回答を直接書かない
- position で挿入位置を指定し、依存関係に沿って並べる

といった制約を課している。さらに、各サブアクションに必須とされる context には、前提条件・制約・依存関係、および成果物を 1~2 文で記述することを要求しており、これによって各ステップは、当該エージェントの Int-To が付随情報とともに明示された単位としてプラン文書上に記録される。

3.4.2 合意フェーズ

合意フェーズは、プラン構築フェーズで得られた暫定レシピ R_α と担当表に対して、「この共通計画だけで本当に α を達成できると言ってよいか」を各エージェントがチェックする段階である。本フェーズでは新しいサブアクションは一切追加せず、すでに記述されている行為と担当の組のみを根拠として、プラン全体の十分性を検証する。この合意判定は、Shared Plans における「この計画で α を達成することにコミットしてよいか」という判断に対応しており、不十分と判断したエージェントは後続の修正フェーズでの手直しを要求する。

本システムでは、各エージェントが返した合意結果を制御部が集約し、全エージェントが同意 (Agreement = true) を返した場合にのみ、合意成立と判定して次の実行フェーズへ遷移する。

このとき、プロンプトではエージェントに対して次の点のみを明示的に指示している。まず TASK では、「プランに書かれている内容のみに基づいて、 α を達成するのに十分かどうかを判定し、真偽と短い理由を返すこと」と指示するこ

とで、想像や暗黙の補完ではなく、あくまで現在の PlanJSON のみを根拠に評価することを徹底している。RULES では、これを支えるために、

- recipe と intention に明示的に書かれているものだけを根拠とし、「あとで誰かが何かやるはずだ」といった暗黙の行為を仮定しない
- ステップの順序はこの段階では無視し、必要な行為が存在するかと、その担当エージェントが適切かどうかだけを見る
- 必要な行為タイプが欠けている、サブアクションをすべて終えても α が達成できない、最後のサブアクションの担当が不適切、のいずれかに該当すれば Agreement を false にする
- それらの欠陥が見当たらない場合には true を返す

という単純な判定基準を与えている。ステップ順序をあえて評価対象から外しているのは、修正フェーズが「不足しているサブアクションの追加」のみに絞られており、順序調整まで考えさせると LLM の判断を過度に複雑にしまうためである。また、最後のサブアクションの担当エージェントだけは例外的にチェックすることで、最終的な回答を出す役割が適切なドメインに置かれているかどうかを確認しつつ、不足検出に焦点を絞った軽量の合意判定を実現している。

3.4.3 修正フェーズ

修正フェーズのプロトコルを図 5 に示す。本フェーズの基本的な発想はプラン構築フェーズと同様であり、現在の共有プランを参照し、各エージェントが自分のドメインで本当に必要なサブアクションのみを追加する設計に従う。ただし本フェーズでは、合意フェーズで得られた不同意理由を入力として与えることで、埋めるべき不足が明示された状態から修正を開始する点に特徴がある。各エージェントはまず、不同意理由と現状の Plan を読み、自身のドメインで解決可能であれば、前後の推論との接続を考慮してサブアクションを追加する。このとき context には、当該サブアクションで得る情報・判断と、不同意理由で指摘された不足をどのように埋めるかを記述させ、どの不足に対応する Int-To なのかをプラン文書上で追跡可能にする。

修正手順としては、制御関数が不同意理由を保持したまま、全エージェントに順に修正可否を問い合わせ、いずれかが修正を行った時点でその修正を確定し、更新後の Plan で合意フェーズへ差し戻す。一方、誰も修正しない場合は最終フォールバックとして、不同意を出したエージェントに強制修正を実行させる。この強制修正では、通常の修正と異なり、そのサブアクションを自分以外の




図 5 修正フェーズの Protokol

適切なエージェントに割り当てることを許可する．これにより，全員が自ドメイン内では修正不能と判断した場合でも，解決の1手を補正できる．強制修正でも修正が得られない場合は，これ以上の調整は不可能と判断してProtokolを終了する．合意→修正→再合意のループは最大5回までとし，不足の解消と過剰な再計画の抑制を両立させている．

3.4.4 実行フェーズ

実行フェーズは，合意済みとなったレシビ R_a と担当表に基づいて，各エージェントが自分に割り当てられたサブアクションを順番に実行する段階である．ここでは，プラン構築フェーズで Int-To の単位として書き出された各ステップが，実際の推論行為として呼び出され，各サブアクションの context とこれまでの実行履歴を参照しながら，外部知識も用いて具体的な情報獲得や判断へと変換される．こうして得られた state, result, final_answer は実行ログとして蓄積され，最後のステップのエージェントによる最終回答生成の土台となる．

このとき、プロンプトではエージェントに対して、次の点だけを明示的に指示している。まず TASK では「プラン中のサブアクション文と、対象サブアクションコンテキスト、そしてこれまでの実行履歴に基づいて、自分のドメインの範囲でそのステップを実行し、短い結果と達成度、必要に応じて `final_answer` を返すこと」と指示することで、計画全体ではなくあくまで今の 1 ステップの遂行に集中させている。RULES では、これを支えるために、

- 知識と推論を自分のドメインに制限しそれ以外の領域には踏み込まない
- 実行履歴に含まれる既存の事実を主な根拠としつつ、それと矛盾しない範囲で世界知識による補完を認める
- 実行対象は自身のサブアクションのみに限定する
- 得られた成果に応じて `state` を `success/partial/fail` のいずれかで明示し、`result` は 2 文以内で簡潔に記述する
- 最終ステップかどうかのフラグに応じて `final_answer` の有無を切り替え、最後のステップでは α に対する短い最終回答だけを出力する

という基準を与えている。これにより、各ステップは「自分のドメインに閉じた局所的な Int-To の実行」として扱われ、成果が履歴に蓄積される。特に `state` は、各サブアクションがどれだけ達成できているかを表すことで、後続のエージェントが「どのステップは十分に処理済みで、どのステップは情報が不足しているのか」を一目で把握できるようにし、共有プラン上での状況理解を支援する役割を果たしている。

第4章 実験

4.1 実験設定

本章では、提案した SharedPlans 型マルチエージェント手法の有効性を検証するために行った実験について述べる。本研究では、クロスドメインな推論を必要とする質問応答タスクとして HotpotQA ベンチマークを用い、代表的な単一エージェント手法および提案手法以外マルチエージェント手法と比較する。あわせて、SharedPlans に基づくプラン構造やエージェント間のタスク分担を分析し、提案手法がどのような問題設定において有利／不利となるかを考察する。

本節では、実験に用いたデータセット、比較手法、評価指標についてそれぞれ説明する。定量的な結果およびアブレーション実験の詳細は次節以降で述べる。

4.1.1 実験データセット

本研究では、マルチホップ質問応答ベンチマークである HotpotQA データセット[5]を用いて提案手法の。HotpotQA は複数の Wikipedia 記事にまたがる推論を要求することを特徴とし、複数のドメインに跨るクロスドメイン QA を含んでいる。

評価に用いる問題集合としては、HotpotQA の中でも、問題タイプが bridge かつ難易度が hard に分類される問題から、100 問をランダムに抽出して使用した。bridge 型の問題は、中間となる「橋渡しエンティティ」を経由して複数の記事を関連付ける必要があり、さらに hard 難易度は質問表現や証拠構造が比較的複雑であることから、複数ドメインの知識を統合するマルチステップ推論が求められる。本研究では、これら 100 問を共通の評価セットとして、各比較手法に同一の問題を与え、回答性能と協調過程の違いを比較・分析する。

4.1.2 ベースライン

提案する SharedPlans 型マルチエージェント手法の有効性を確認するため、以下の 4 条件を比較対象として設定した。いずれの条件も基盤モデルには gpt-5-mini を用いる。また、比較実装では提案手法と同一のドメイン領域定義を与え、ドメイン領域外の新規知識の導入や行動を抑制することで、条件間の公平性を担保した。また、各手法を 2 回ずつ実装し、平均値を今回のデータとして扱うことで、LLM の確率的出力によるばらつきの緩和を図った。

1. シングルエージェント (Zero-Shot)

単一の LLM に質問文のみを入力し、「短い最終回答のみを出力せよ」と指示する条件である．明示的なプラン生成は行わず，ドメイン制約つきの汎用 QA 能力を評価する．回答形式は提案手法と揃え，複数候補はカンマ区切り，候補が全くない場合は Null を出力するようプロンプトで指定した．

2. シングルエージェント (Plan-and-Solve)

Zero-Shot に対し，“Let’s first understand the problem and devise a plan to solve it. Then, let’s carry out the plan and solve the problem step by step.”という文を付加し，まず質問に答えるための簡単なプランを列举させ，その後でそのプランを参照しながら最終回答を生成させる条件である．タスク分解と逐次推論は行うものの，計画立案と最終決定はいずれも単一エージェントに依存する．本研究では，最終回答だけでなくこのプランもログとして保存し，提案手法との違いの分析に用いた．

3. マルチエージェント (直列プロトコル)

複数のドメイン別エージェントを用意し，ランダムな順序で直列に呼び出す構成である．各エージェントは質問文とそれまでの実行ログ (HISTORY) を入力として受け取り，HISTORY を参照して「不足している観点」を把握することは許可されるが，contribution の生成は自分のドメインに厳密に制限され，HISTORY に含まれる非ドメイン情報を根拠として再利用・言い換え・補強することは禁止されている．そのため，各エージェントは「自分のドメイン内で追加できる情報がある場合のみ 1 文で貢献し，それ以外は Null を返す」という動作となる．一方で最終ステップに限り，final_answer については例外的に HISTORY に明示されたエンティティや事実を利用でき，最後のエージェントがそれまでの貢献を踏まえて最終回答 (final_answer) を決定する．この条件では SharedPlans のような明示的なプラン構造 (R_α や Int-To) は共有されず，各エージェントは共通計画ではなく実行ログの読解とドメイン制約に基づいて逐次的に貢献する直列型マルチエージェント基準として位置づけられる．

4. マルチエージェント (並列プロトコル)

直列プロトコルと同じく複数エージェントを用いるが，5 つのエージェ

ントを互いに独立に並列実行する条件である。各エージェントは、共通の質問文と自分のドメイン説明のみを入力として受け取り、他エージェントの出力にはアクセスせずに候補回答を生成する。実行後、5つの候補のうち最も多くのエージェントが出力した文字列を最終回答として採用する単純な多数決規則を用いる。明確な多数がない場合も最頻の回答を選択し、一意の最終回答を得る。この条件も SharedPlans によるプラン共有は行わず、「複数の専門家が独立に答え、最後に多数意見を採用する」タイプのマルチエージェント基準として位置づける。

4.1.3 評価指標

評価指標は、HotpotQA で用いられている Exact Match (EM) と token ベースの F1 を基本として実装した。いずれの指標も、共通の正規化手続きに基づいて算出している。まず、予測データと正解データに対して、英字の小文字化、句読点の削除、英語冠詞 (a, an, the) の削除、および余分な空白の統一といった正規化処理を行う。これにより、「Barack Obama」と「barack obama」などの表記揺れを同一として扱うことができる。その後、文字列の完全一致による EM スコアの判定と、語レベルの各指標の計算を行う。

正規化後の予測回答を P 、正解回答を G 、それぞれの単語集合の共通部分を $C = P \cap G$ とすると、各指標は次のように定義される。

- ・ precision (語レベルの適合率)

$$\text{Prec} = \frac{|C|}{|P|} \quad (1)$$

= 「予測に含まれる単語のうち、正解にも含まれている単語の割合」

- ・ recall (語レベルの再現率)

$$\text{Rec} = \frac{|C|}{|G|} \quad (2)$$

= 「正解に含まれる単語のうち、予測にも含まれている単語の割合」

- ・ F1 (語レベルの F1 スコア)

$$\text{F1} = \frac{2 \cdot \text{Prec} \cdot \text{Rec}}{\text{Prec} + \text{Rec}} \quad (3)$$

(Prec と Rec がともに 0 の場合は $\text{F1} = 0$ とする)

しかし、HotpotQA の回答には、言い換えや部分的な記述の違いにより、EM や token ベースの F1 では十分に捉えきれない意味的一致が存在する．そこで本研究では、これらの自動指標に加えて、LLM を評価者として用いた GPT ベース評価 も併用した．具体的には、質問文・正解回答・モデルの予測回答を入力として GPT に提示し、意味内容が実質的に一致しているか否かを判定させ、一致と判断された場合を 1、不一致の場合を 0 とする二値指標を算出した．GPT には、数値や固有名詞が完全に一致していない場合でも、「同じ人物を指している」「同じ事実を別表現で述べている」などの意味的同値を判断するよう指示している．これにより、EM/F1 が過小評価しやすい言い換え表現を補完しつつ、提案手法と比較手法の回答品質を多面的に評価できるようにした．

4.2 実験結果

4.2.1 2 ドメイン

ドメイン数を 2 に制限した条件では、以下の 2 領域を使用した．

- People：人物に関する知識（人物同定、属性・経歴、人物関係）
- Geography：地理・場所に関する知識（国・都市・施設、所在・包含関係）

結果を表 1 に示す．ドメイン 2 条件（People+Geography）では、提案手法が最良となった．また Null は 73/200 で、他手法（126～145）より大幅に少ないことが結果として現れた．

4.2.2 5 ドメイン

ドメイン数を 5 に拡張した条件では、上記の 2 領域に加えて、以下の 3 領域を使用した．

- Entertainment：エンターテインメントに関する知識（作品・楽曲・出演）
- Business：企業・組織に関する知識（組織同定、提携・買収などの関係）
- Sport：スポーツに関する知識（大会、選手・チーム、所属・成績の関係）

表 1 2 ドメインを用いた実験結果

手法	EM	F1	precision	recall	GPT	Null (200 件)
提案手法	0.250	0.365	0.359	0.398	0.400	73
Zero-Shot	0.200	0.228	0.230	0.236	0.285	133
Plan-and-Solve	0.180	0.208	0.204	0.218	0.240	145
直列	0.220	0.262	0.258	0.276	0.305	126
並列	0.190	0.225	0.222	0.233	0.250	138

表 2 5 ドメインを用いた実験結果

手法	EM	F1	precision	recall	GPT	Null (200 件)
提案手法	0.280	0.419	0.403	0.472	0.540	51
Zero-Shot	0.365	0.436	0.437	0.447	0.500	74
Plan-and-Solve	0.365	0.435	0.437	0.445	0.515	70
直列	0.340	0.423	0.421	0.440	0.485	83
並列	0.360	0.394	0.394	0.403	0.450	90

結果を表 2 に示す. EM/F1 は Zero-Shot/Plan-and-Solve が僅差で上回る一方、提案手法は Null 最少 (51) で失敗が最も少ない. さらに GPT 評価が最高 (0.540) となり、総合的には提案手法が最も有利な結果となった.

4.2.3 10 ドメイン

ドメイン数を 10 に拡張した条件では、上記 5 領域に加えて、以下の 5 領域を使用した.

- Politics : 政治に関する知識 (政治家, 制度・政策, 歴史的 political 事象)
- Transportation : 交通・インフラに関する知識 (交通手段, 交通インフラ)
- Demographics : 人口・社会統計に関する知識 (人口規模・分布, 民族・言語, 宗教割合などの比率・統計表現)
- Science : 科学技術に関する知識 (科学概念, 技術分野)
- Education : 教育に関する知識 (教育制度・機関, 学習段階, 教育内容)

結果を表 3 に示す. ドメイン 10 条件では、EM/F1・GPT 評価ともに既存手法 (Zero-Shot/直列) が上位となった. 提案手法は Null 数も改善されず (72/200)、ドメイン数増加による不利が顕在化した.

表 3 10 ドメインを用いた実験結果

手法	EM	F1	precision	recall	GPT	Null (200 件)
提案手法	0.215	0.327	0.311	0.370	0.415	72
Zero-Shot	0.390	0.463	0.468	0.470	0.545	69
Plan-and-Solve	0.390	0.456	0.458	0.464	0.520	66
直列	0.380	0.473	0.468	0.490	0.540	67
並列	0.370	0.447	0.450	0.456	0.515	75

4.3 アブレーションテスト

提案手法の重要要素である合意形成フェーズと共有計画参照が性能向上に寄与しているかを検証するため、それぞれを除去したアブレーションテストを行った。具体的には、計画生成後の合意・修正を省略してそのまま実行に移る「合意フェーズなし」条件と、合意は行うが実行時に共有計画を提示せず action_log のみで逐次実行する「プラン共有なし」条件を設定し、5つのドメインを用いた例で提案手法と比較した。

表 4 が結果である。合意フェーズなし条件では、計画生成後の合意・修正プロセスを省略し、初期プランのまま実行フェーズへ遷移させた。この結果、全ての評価指標数値が大きく低下し、Null は 51→70 に増加した。これは、合意形成が担っていた 計画品質の保証が失われ、不完全な計画のまま実行されることで、前提・最終回答アクションの欠如状態に陥りやすくなったためと解釈できる。

プラン共有なし条件では、EM は提案手法と同程度である一方、その他指標が低下し、Null 数も増加した。これは、実行中に共有計画が提示されないため、推論が局所的な履歴追従に偏り、計画全体の見通しを保ったまま情報を接続できなくなるためと考えられる。実際、問いが要求する制約を保持できずに推論が逸脱する、次に埋めるべき未解決点の共有が弱まり必要な情報収集が生じにくい、といった形で実行過程が不安定化する傾向が観測された。これより、共有計画の実行時参照は、推論中の制約保持と工程連結を支えることで、誤答や Null の増加を抑制する役割を担う。

以上より、提案手法の性能向上はマルチエージェント化によるものではなく、合意形成と共有計画参照の 2 要素が異なる役割で精度向上に寄与していることが示された。合意形成は実行前に plan の欠落・不整合を除去して役割分担と工程を確定し、Null を抑制する。一方、共有計画参照は実行中に α 達成までの流れと依存関係を保持したまま部分結果の接続を可能にし、誤答や取りこぼしを抑える。したがって提案手法の有効性は、「計画を合意で整備し、実行中も共通の参照枠として運用し続ける」設計に基づく、安定性と回答精度の両立にある。

表 4 アブレーションテスト結果

手法	EM	F1	precision	recall	GPT	Null(200 件)
提案手法	0.280	0.419	0.403	0.472	0.540	51
合意フェーズなし	0.135	0.258	0.238	0.335	0.345	70
プラン共有なし	0.285	0.358	0.347	0.402	0.445	75

第5章 考察

5.1 ドメイン数に応じた提案手法の特性

5.1.1 各ドメインにおける解答例

本提案手法においてドメイン数を変化させた場合の挙動を分析するため、同一問題“Be Quick’ 28 footballclub is located in what province?”に対する実行ログを対象として考察を行った。本設問の対象クラブ（BeQuick’ 28）はオランダの Zwolle に拠点を置き、所在地州は Overijssel である。本節では、この正解に至るまでの計画構造および実行過程に着目し、ドメイン数の増減が行動主体性と計画の収束の仕方にどのような影響を与えるかを分析する。

ドメイン 2 およびドメイン 5 では、計画構造や使用するドメイン数は異なるが、いずれも最終的に正解である Overijssel に到達している。両者に共通するのは、対象クラブの同定が実行過程の比較的早い段階で確定し、その後の処理がその同定結果を前提とした確認として機能している点である。ドメイン 2 では、PeopleAG が自ドメインでは州を特定できないことを fail として明示し、地理情報を担当する GeographyAG へ処理を委譲することで、同定と州確定が行われた。ドメイン 5 では、BusinessAG によってクラブが Zwolle に所在することが早期に共有され、後続の地理的検証と統合処理が安定して収束している。このように、ドメイン数の多少に関わらず、「同定に必要な役割が適切に機能し、未確定な状態が明示される」場合には、計画は停止せず正解に到達することが確認できる。

一方でドメイン 10 では、識別、重複確認、ジオコーディング、行政記録照合、法人登録確認など、多数の検証工程を含む詳細な計画が構築されていた。形式的には網羅性の高い計画であるが、実行過程では初期段階で SportAG が提示した「当該クラブは Groningen に所在する」という仮説が暗黙の前提として固定されている。PeopleAG による名称整理や DemographicsAG による重複確認は、本来であればクラブ同定を再検討する役割を担うが、いずれもこの初期仮説を明示的に否定する情報を提示できず、結果として仮説の再検証には至っていない。

その後の ScienceAG, PoliticsAG, GeographyAG による処理は、「Groningen 市が Groningen 州に属する」という地理・行政的整合性を確認する方向に作用しており、「当該クラブが本当に Groningen 市に所在するか」という前提自体を問い直す工程にはなっていない。特に、住所情報や法人登録情報が取得できなかった

ことで、仮説を修正・分岐させる契機が生じず、各検証工程は同一前提の下での確認を重複して実行する構造となった。その結果、検証工程が増えるほど初期仮説が多方面から補強され、誤った同定に基づく推論が「根拠の多い結論」として固定化されている。このようにドメイン 10 では、検証工程が増加しているにもかかわらず、初期仮説の再検証が行われないうまま推論が進行しており、結果として誤った前提に基づく結論に収束していることが確認できる。

5.1.2 ドメイン数の増減による回答精度への影響

仮説では、利用するドメイン数を増やすことで多様な観点からの検証が可能となり、回答精度は向上すると想定していた。しかし本実験では、10 ドメインの精度 (0.415) が 5 ドメイン (0.54) を下回り、ドメイン数の増加が必ずしも性能向上につながらないことが確認された。本節では、この逆転現象を行動主体性と計画停滞の観点から分析する。

ドメイン数を比較すると、ドメイン数の増加が性能に与える影響は段階ごとに異なる。ドメイン数の 2 から 5 への変化は、主としてドメイン制限の緩和として解釈できる。2 ドメインでは知識範囲が狭く、解答に必要な情報が構造的に不足する問題がある一方、5 ドメインでは代表的ドメインが概ね揃い、情報不足による探索不能や誤答が減少した。この段階でのドメイン増加は到達可能性の拡張として機能している。

一方、ドメイン数の 5 から 10 への変化は、単なる制限緩和では説明できない。5 ドメインの時点で必要ドメインは多くの問題で満たされており、10 ドメインの性能低下は、行動主体性の低下と責任分散に起因すると考えられる。2 ドメインや 5 ドメインでは関与 AG 数が少なく、未完了工程が生じて「自分が引き受ける／他 AG に委譲する」の判断が容易な傾向が見受けられた。実際に、実行ログでも、処理不能を fail として明示し、適切な AG に委譲することで計画を停止させない振る舞いが繰り返し観測され、これが回復的な行動主体性として機能していた。

これに対し 10 ドメインでは、多数の AG が関与することで責任の所在が曖昧になりやすいケースが目立った。各 AG は自ドメイン内で妥当な検証を行う一方、「未確定な前提の回復を誰が担うか」が不明瞭になり、同定失敗や情報欠落が生じて再同定や計画修正が起こりにくい。その結果、初期仮説が十分に検証されないまま共有前提として固定され、後続 AG の処理が探索ではなく確認的補強に偏る事例が複数見られた。このとき、各工程は局所的に妥当でも、全体として未

確定前提が解消されないまま維持され、誤った推論経路が強化される。

さらに 10 ドメインでは工程が詳細化しやすいが、工程間の実行可能性や最終回答までの責務の連続性が十分に検査されずに工程が追加される場合がある。その結果、最終段階で担当 AG がドメイン外での fail や、必要前提が欠落したまま比較・統合が要求され、Null に至るケースが増加した。工程数の増加は行動主体性の向上ではなく、責任分散と最終責任の希薄化を招いたと解釈できる。

以上より、「ドメイン数の増加≠行動主体性の増加≠精度向上」ということがわかる。検証観点は多様化しても、行動主体性が維持されなければ計画は探索的に進まず、確認的処理の反復や停滞を引き起こす。性能向上には、ドメイン数の単純な増加ではなく、各工程における責務の明確化と、失敗時に回復行動を引き受ける主体を計画構造内に明示する設計が重要である。

5.2 ベースラインとの比較

本評価では、提案手法と比較手法の双方に同等のドメイン制限を課したうえで、ドメイン数を 2, 5, 10 に変化させて性能を比較した。比較手法では、ドメイン数の増加に伴い Null が減少し、精度が段階的に改善する傾向が見られた。これは、共有計画や合意に基づく役割補正を持たない手法では、「到達可能な情報量」に依存しやすいためである。Zero-Shot は質問全体を一括で処理するため、必要な根拠がドメイン外にまたがると初期段階で回答不能となりやすく、Plan-and-Solve も分解と実行の主体が単一である以上、途中で必要情報が得られない場合に代替工程へ切り替える契機が弱い。直列型や並列型も、共通の工程列や担当が明示されないため、部分情報が得られても最終回答へ収束させる統合工程が自動的に起動されにくい。したがってドメイン数が増えるほど、偶然的にでも必要事実へ到達できる確率が上がり、結果として性能が改善しやすい。

一方提案手法は、ドメイン数の増加と共有計画と協調プロトコルによって「実行可能な工程への焦点化」と「不足工程の補完」が促進される点で比較手法と異なる。plan により工程と責務が明示され、合意フェーズで工程欠落や担当曖昧さが補正されるため、ドメイン 2 のように知識範囲が狭い条件でも停止せずに次の工程へ進み、Null の連鎖を抑制しやすい。ドメイン 10 のように過度に増やすと、責務の希薄化や確認的処理への偏りで性能が単調増加しない局面も生じる。この要因は 5.1 で述べた通りであり、提案手法の性能は「到達可能性の拡張」と「行動主体性の維持」のバランスに依存することが示唆される。

第6章 おわりに

本研究は、複数分野にまたがるクロスドメイン QA において、単一エージェントへの推論集中が引き起こす誤前提の固定化やハルシネーション連鎖を抑制するために、SharedPlans 理論に基づくマルチ LLM エージェント協調手法を提案した。提案手法では、グループ目標 α を中心に、サブアクション列 recipe, 前提条件 context, 各エージェントの担当を表す intentions を明示的に保持し、計画構築、合意形成、実行、最終回答生成を段階的に進める協調プロトコルを実装した。これにより、各エージェントは自身のドメイン制約を保ったまま実行可能な工程へ焦点化し、失敗や情報不足が生じても工程の補完と推論継続を促進できる構造を実現した。

HotpotQA を用いた評価では、提案手法がシングルエージェント手法および共有計画を用いないマルチエージェント手法と比較して、総合的に高い回答性能を示した。特に、ドメイン制限下でも Null の連鎖を抑制し、必要な工程を補完しながら回答まで到達する挙動が観測され、SharedPlans に基づく責務の明示と合意フェーズが協調過程の安定化に寄与することが確認できた。一方で、ドメイン数を過度に増やした条件では、責任分散や確認的处理への偏りが生じ、ドメイン追加が性能向上に直結しないことも示された。以上より、本研究は、クロスドメイン QA においては、マルチエージェント構成に加えて、共有計画に基づく責務の設計と協調プロトコルの整備が、性能と安定性を左右する重要な要因であることを示した。

本研究の協調プロトコルは、共有計画に基づく工程分解と責務割当によって、ドメイン制限下でも推論を継続しやすい点を示した。一方で実行フェーズにおいて、外部根拠の取得失敗や同定誤りが生じた場合に、推論の軌道をどのように修正するかは重要な課題として残る。軌道修正には大きく再計画とプロンプトでの強制の 2 手法が考えられる。再計画は、実行失敗や状況変化に応じて計画を更新することで欠落工程や不整合を構造的に修正でき、計画全体の整合性を明示的に維持しやすい。しかし頻繁な再計画はトークン使用量を大きく増加させ、工程の増殖により計画が分散、発散しやすい。また複数エージェントが並行して修正提案を行う場合、協調より競合が起きやすい可能性もある。一方、プロンプトでの強制は、計画構造を変えずに出力行動のみを制御し、これまでの実行の不足点を即時にカバーできるため、実装が容易でトークン増加も抑えられる。しか

しこの方式は協調的修正というより分散的な試行錯誤に近づきやすく、ドメイン間の関係が複雑化して整合性が崩れるリスクがある。今後は、失敗の種類に応じて両者を切り替える発動条件の設計、工程増殖を抑える制約、および最終責任主体の明確化を含め、低コストで安定した軌道修正機構を協調プロトコル内に統合することが必要である。

謝辞

本研究を行うにあたり，熱心なご指導，ご助言を賜りました村上陽平教授に深く感謝申し上げます．また，普段からお世話になっている社会知能研究室の皆様にも心より感謝申し上げます．

参考文献

- [1] Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E. H., Le, Q. V., Zhou, D.: Chain-of-Thought Prompting Elicits Reasoning in Large Language Models, *Advances in Neural Information Processing Systems*, 35 (2022).
- [2] Wang, L., Xu, W., Lan, Y., Hu, Z., Lan, Y., Lee, R. K.-W., Lim, E.-P.: Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models, *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL 2023)*, pp.2609-2634 (2023).
- [3] Wu, F., Li, Z., Wei, F., Li, Y., Ding, B., Gao, J.: Talk to Right Specialists: Routing and Planning in Multi-agent System for Question Answering, *CoRR*, abs/2501.07813 (2025).
- [4] Grosz, B. J., Kraus, S.: Collaborative Plans for Complex Group Action, *Artificial Intelligence*, 86, 2, pp.269-357 (1996).
- [5] Yang, Z., Qi, P., Zhang, S., Bengio, Y., Cohen, W. W., Salakhutdinov, R., Manning, C. D.: HotpotQA: A Dataset for Diverse, Explainable Multi-hop Question Answering, *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP 2018)*, pp.2369-2380 (2018).

付録

A.1 提案手法ドメイン数ごとの実行例

考察で分析した例を示す.

```
===== Q (90) =====
question: Be Quick '28 football club is locayed in what province?
alpha: Generate answer this question 『Be Quick '28 football club is locayed in what province?』

# plan_doc
question: 90
alpha: Generate answer this question 『Be Quick '28 football club is locayed in what province?』
recipe:
- act: Determine Be Quick '28's province
  context: Verify which province the football club Be Quick '28 is registered in (obtain the club's province), because the correct provincial location is the key fact required to answer  $\alpha$  reliably; place this first since identifying the location is a prerequisite to giving the final answer and may be followed by citing a supporting source if needed.
- act: Verify Be Quick '28's province and cite source
  context: I will obtain and confirm the club's registered province by cross-checking authoritative geographic/club or municipal sources, because verifying and citing the province prevents giving an incorrect or unsupported answer for  $\alpha$ . Place this after PeopleAG's determination (position 2) since verification depends on the initial finding and may still require formatting the final answer or adding a human-readable citation.
- act: Format final answer stating Be Quick '28's province and citation
  context: I will produce the final human-readable answer using the verified province and append the verification source, obtaining the deliverable required for  $\alpha$ . This assigns ownership for producing the output and must follow verification, so place it after the verification step (position 3).
intentions:
- agent: PeopleAG
  action: Determine Be Quick '28's province
- agent: GeographyAG
  action: Verify Be Quick '28's province and cite source
- agent: PeopleAG
  action: Format final answer stating Be Quick '28's province and citation
context: Use your domain information to achieve alpha with team agents

# action_log
- [PeopleAG] (fail) Determine Be Quick '28's province → Cannot determine Be Quick '28's province within my people/biographical domain; external geographic/club sources are required. I must defer to GeographyAG for verification.
- [GeographyAG] (success) Verify Be Quick '28's province and cite source → Be Quick '28 is based in Zwolle, in the province of Overijssel (Netherlands); authoritative confirmation can be found on the club's official website and the KNVB club directory.
- [PeopleAG] (success) Format final answer stating Be Quick '28's province and citation → Be Quick '28 is based in Zwolle, in the province of Overijssel, Netherlands; verification available on the club's official website and the KNVB club directory.

# final_answer
```

図 6 2 ドメインの実行例

===== Q (90) =====

question: Be Quick '28 football club is located in what province?

alpha: Generate answer this question 『Be Quick '28 football club is located in what province?』

plan_doc

question: 90

alpha: Generate answer this question 『Be Quick '28 football club is located in what province?』

recipe:

- act: Verify Be Quick '28 official name and legal domicile

context: I will obtain the club's official/registered name and its legal/registered domicile for Be Quick '28 to disambiguate similarly named clubs and ensure we report the correct province. This is a prerequisite (placed first) because answering the province reliably depends on confirming the exact municipal registration; mapping that municipality to its province may require a follow-up lookup.

- act: Confirm Be Quick '28 common names and associated city

context: I will obtain commonly used name variants and the club's commonly associated municipality from biographical and sports-reference sources to confirm that the legal/registered domicile BusinessAG finds matches the club intended; this prevents misidentifying similarly named clubs and ensures we map the municipality reliably to its province. Place this after the legal-domicile check so I can compare official registration with common usage; if discrepancies appear, further reconciliation of sources may be needed.

- act: Normalize and geocode reported municipality names

context: I will obtain a canonical municipality name, authoritative geocoordinates, and official administrative assignment from geographic sources to disambiguate similarly named places and produce an objective link to the correct province; this reduces place-name ambiguity and makes the province determination reliable. Place this after BusinessAG and PeopleAG produce their candidate municipality names because it depends on their outputs to know which variants to normalize and geocode; if multiple matches or boundary issues remain I will report the ambiguity and what further source checks are needed.

- act: Reconcile municipality and determine its province

context: I will reconcile BusinessAG's legal-domicile result and PeopleAG's common-city result to decide the club's intended municipality and then identify which province contains that municipality, providing the direct fact needed to answer alpha. Place this after the two verification steps because it depends on their outputs; if sources conflict or remain ambiguous I will list the remaining uncertainty and what follow-up is needed.

intentions:

- agent: BusinessAG

action: Verify Be Quick '28 official name and legal domicile

- agent: PeopleAG

action: Confirm Be Quick '28 common names and associated city

- agent: GeographyAG

action: Normalize and geocode reported municipality names

- agent: SportAG

action: Reconcile municipality and determine its province

context: Use your domain information to achieve alpha with team agents

mutually believe:

all_agreed: true

action_log

- [BusinessAG] (partial) Verify Be Quick '28 official name and legal domicile → Tentatively identify the club as Voetbalvereniging Be Quick '28 with a legal/registered domicile in the municipality of Zwolle (province Overijssel); confidence limited because authoritative registration records were not consulted.

- [PeopleAG] (success) Confirm Be Quick '28 common names and associated city → Common usage: "Be Quick '28" (also seen as "VV Be Quick '28" or "Be Quick Zwolle"); the club is commonly associated with the city of Zwolle.

- [GeographyAG] (success) Normalize and geocode reported municipality names → Canonical municipality: Zwolle (Municipality of Zwolle), Netherlands; coordinates ≈ 52.5167°N, 6.0833°E. Administrative assignment: Province of Overijssel (matches the BusinessAG and PeopleAG candidates).

- [SportAG] (success) Reconcile municipality and determine its province → BusinessAG's tentative domicile (Zwolle) aligns with PeopleAG's common-city result and GeographyAG's normalization; the municipality is Zwolle in the province of Overijssel. Conclude Be Quick '28 is located in the province of Overijssel.

図 7 5 ドメインの実行例

===== Q (90) =====

question: Be Quick '28 football club is located in what province?

alpha: Generate answer this question 『Be Quick '28 football club is located in what province?』

plan_doc

question: 90

alpha: Generate answer this question 『Be Quick '28 football club is located in what province?』

recipe:

- act: List Be Quick '28 name variants and distinguishing identifiers

context: I will compile commonly used name variants, founding year and other distinguishing biographical identifiers (e.g., home city or notable club attributes) for Be Quick'28 to disambiguate similarly named clubs; this ensures other agents target the same entity and reduces risk of answering for the wrong club. It should be first so SportAG/DemographicsAG/BusinessAG can use these agreed identifiers before searching; registration or geographic confirmation may still be needed afterward.

- act: Identify Be Quick '28's province

context: I will verify which province Be Quick '28 is located in using my sports-location knowledge because that factual province is the direct answer to α ; this must be the first step as a prerequisite before providing any follow-up city/stadium detail or qualifiers.

- act: Check for duplicate Be Quick '28 clubs and confirm municipality/province

context: I will identify whether multiple clubs use the name Be Quick '28 and confirm the target club's municipality and current administrative province using demographic/administrative records; this prevents misidentifying which club is meant and strengthens the province answer. This should come after SportAG's identification so I can focus the check on the nominated candidate; if the municipality's provincial affiliation changed historically I will flag that for GeographyAG's verification.

- act: Geocode club address and map coordinates to province

context: I will programmatically geocode the DemographicsAG-confirmed club name/address to obtain precise coordinates and map those to current provincial boundaries, producing an independent, data-driven province assignment. This reduces ambiguity when textual records conflict and belongs immediately after DemographicsAG's duplicate-check so I target the confirmed candidate; results may still need reconciliation with official registers by PoliticsAG or BusinessAG.

- act: Verify municipality's official province in government records

context: I will confirm the club's municipality and its legally designated province using national government administrative registers and note any recent municipal boundary changes; this obtains the official jurisdictional mapping needed for α . This should run after DemographicsAG confirms which Be Quick '28 is meant so I target the correct municipality, and before BusinessAG's registered-address check so legal-record lookups use the settled provincial assignment (GeographyAG may still cross-check geographic sources afterwards).

- act: Verify Be Quick '28's registered legal address and province

context: I will retrieve the club's legal-entity registration and official registered address (municipality and province) from national business/association registers to confirm which province the named Be Quick '28 is officially domiciled in, preventing misidentification with similarly named clubs; this should follow DemographicsAG's duplicate check so I target the confirmed candidate and can flag if the club is an unregistered association requiring alternative records.

- act: Verify Be Quick '28's province using geographic sources

context: I will obtain and confirm the province in which Be Quick '28 is located using geographic/place references to ensure the answer to α is accurate and not solely based on sports-domain recall; this reduces the risk of a mistaken province. This verification should follow SportAG's identification as a confirmatory step and may indicate a need to check the club's municipality or official records if any ambiguity remains.

intentions:

- agent: PeopleAG

action: List Be Quick '28 name variants and distinguishing identifiers

- agent: SportAG

action: Identify Be Quick '28's province

- agent: DemographicsAG

action: Check for duplicate Be Quick '28 clubs and confirm municipality/province

- agent: ScienceAG

action: Geocode club address and map coordinates to province

- agent: PoliticsAG

action: Verify municipality's official province in government records

- agent: BusinessAG

action: Verify Be Quick '28's registered legal address and province

- agent: GeographyAG

action: Verify Be Quick '28's province using geographic sources

context: Use your domain information to achieve alpha with team agents

図 8 10 ドメインでの実行例 1

action_log

- [PeopleAG] (partial) List Be Quick '28 name variants and distinguishing identifiers → Common name variants: Be Quick '28; Be Quick 28; SV Be Quick '28; Sportvereniging Be Quick '28; BeQuick28 (apostrophe sometimes omitted). Key distinguishing identifiers to confirm the intended club: founding year (likely 1928), home municipality/city, KNVB registration number and competition level (amateur/division), club colours and home-ground name—verify these to avoid confusion with similarly named clubs (e.g., Be Quick 1887).
- [SportAG] (partial) Identify Be Quick '28's province → Based on sports-domain recall and the name variants identified by PeopleAG, Be Quick '28 is most likely located in the province of Groningen; I mark this as partial pending DemographicsAG confirmation of the exact municipality to avoid confusion with similarly named clubs.
- [DemographicsAG] (partial) Check for duplicate Be Quick '28 clubs and confirm municipality/province → I find no clear evidence of multiple distinct clubs named "Be Quick '28" among commonly referenced Dutch clubs; SportAG's candidate appears to be the primary one and is associated with the municipality of Groningen (province Groningen), but definitive municipality/province confirmation requires administrative register checks.
- [ScienceAG] (partial) Geocode club address and map coordinates to province → No precise club street address was provided to geocode; using the DemographicsAG candidate municipality (Groningen) I map the city centroid (~53.2194°N, 6.5665°E) which falls inside the province of Groningen. For authoritative geocoding I need the club's registered street address or official registry entry to compute exact coordinates and confirm provincial boundaries.
- [PoliticsAG] (success) Verify municipality's official province in government records → I confirm the municipality of Groningen is officially in the province of Groningen according to national government administrative registers. Note: the municipality expanded when Haren and Ten Boer were merged into Groningen on 1 January 2019, but its provincial affiliation remained Groningen.
- [BusinessAG] (partial) Verify Be Quick '28's registered legal address and province → I could not locate a definitive Chamber of Commerce (KvK) registration number or legal-entity record for Be Quick '28 within my business-registration domain; the club appears to be an amateur sports association (SV Be Quick '28) associated with the municipality of Groningen. Definitive verification of the club's registered legal address and province requires a direct KvK/company-register lookup or the club's formal statutes/registration documents.
- [GeographyAG] (success) Verify Be Quick '28's province using geographic sources → Cross-checking the nominated municipality (Groningen) against provincial boundary maps and city centroid coordinates places Be Quick '28 within the province of Groningen. Provincial assignment confirmed by geographic-place references.

final_answer

Groningen

図 9 10 ドメインでの実行例 2